

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Черноусов Данила Владиславович

**ГЕОМЕТРИЧЕСКИЙ ПОДХОД К ОЦЕНКЕ
СЛОЖНОСТИ ДАННЫХ НА ОСНОВЕ ГЕНЕРАТИВНЫХ
ДИФФУЗИОННЫХ МОДЕЛЕЙ**

03.03.01 — Прикладные математика и физика

Выпускная квалификационная работа бакалавра

Научный руководитель:
Грабовой Андрей Валериевич,
кандидат физико-математических наук

Москва — 2026

Содержание

1	Введение	4
2	Постановка задачи	7
3	Предлагаемое решение	9
3.1	Мера сложности и положительно полуопределённые ядра . . .	9
3.2	Критерий положительной определённости ядра	12
3.3	Условно отрицательно определённые расстояния в L^p	13
3.4	Реализация: траекторное вложение	14
4	Вычислительные эксперименты	17
4.1	Алгебраические свойства	17
4.2	Поточечное вложение и его ограничения	17
4.3	Траекторное вложение	17
4.4	Изображения MNIST	18
5	Заключение	18
A	Доказательства	21

Аннотация

Во многих задачах машинного обучения важно оценивать не только объём, но и разнообразие обучающей выборки, причём без опоры на разметку: это нужно для прогнозирования качества моделей, для отбора обучающих подвыборок и для сравнения наборов данных одного объёма, но разного содержания. Существующие меры сложности данных описывают лишь локальную размерность или опираются на готовые признаковые представления и не улавливают семантическую геометрию порождающего распределения, то есть то, насколько объекты выборки близки по смыслу и на каких масштабах. В работе предлагается извлекать эту геометрию из предобученной диффузионной модели: каждому объекту сопоставляется его траектория в порождающем процессе, описывающая объект сразу на всех масштабах, а сложность выборки оценивается как эффективный объём, который она занимает в пространстве траекторий. Установлены достаточные условия корректности меры и доказаны теоремы о её свойствах, предложен способ её вычисления через траектории диффузионной модели, экспериментально показано семантическая согласованность предложенной меры.

1 Введение

Качество модели машинного обучения определяется не только объёмом обучающей выборки: две выборки одинакового размера могут заметно различаться по разнообразию и информативности, а с ними и по тому, насколько сложную модель они позволяют обучить и насколько хорошо она обобщает [1; 2]. Это видно уже на простых примерах. Набор из тысяч почти одинаковых кадров одного видеоролика или из множества сдвигов и небольших поворотов одного изображения формально велик, но содержательно беден: все его объекты получены из одного и почти не добавляют разнообразия [3]. По той же причине число токенов, привычная ось в законах масштабирования качества [4], слабо отражает информативность текстового корпуса: токены сильно зависимы и избыточны [5], и удаление дубликатов или отбраковка лишних примеров способны не ухудшить обучение, а улучшить его [6; 7]. В подобных случаях информативен не объём, а эффективный размер выборки. Это понятие давно формализовано в статистике: зависимые или избыточные наблюдения несут меньше информации, чем столько же независимых, и реальное число объектов может многократно превышать эффективный размер выборки [8; 9]. Поэтому возникает потребность в мере сложности выборки, которая численно отражала бы это разнообразие и была бы согласована с геометрией порождающего распределения. Такая мера полезна для прогнозирования качества модели по характеристикам данных, для адаптивного обучения, то есть отбора обучающих подвыборок с учётом их сложности [10; 11], и для сравнения наборов данных одного объёма, но разного содержания [12; 13].

Существующие меры сложности данных можно разделить на два рода. Одни оценивают сложность задачи классификации по размеченной выборке: меры перекрытия признаков и разделимости классов Хо и Басу [14], систематизированные в обзоре [15], оценки трудности отдельных объектов [16], а также классические меры ёмкости класса гипотез, размерность Вапника–Червоненкиса [17] и сложность Радемахера [18]. Все они отвечают на вопрос, насколько трудно выучить разметку, и не определены без меток.

Другие меры оперируют только объектами, без меток. Сюда относятся оценки внутренней размерности многообразия данных, в том числе с помощью диффузионных моделей [19; 20], и информационные меры на основе

энтропии и взаимной информации [21]. Ближайшее к предлагаемой мере семейство, спектральные меры разнообразия, сводит выборку к спектру положительно полуопределённой матрицы похожести: Vendi Score [22] и его обобщение на порядки Реньи [23] берут экспоненту энтропии нормированного спектра, а лог-детерминантный объём детерминантных точечных процессов [24] и эффективный ранг [25] суть родственные спектральные функционалы того же ядра. Примыкает направление оценки достаточного объёма выборки и сложности моделей [26—28].

Общий недостаток перечисленных подходов в том, что они либо описывают лишь локальную размерность, либо опираются на готовые признаковые представления и не учитывают семантическую геометрию порождающего распределения: то, насколько объекты выборки близки или далеки по смыслу и на каких масштабах.

В настоящей работе семантическая геометрия данных извлекается из предобученной диффузионной модели. Такая модель кодирует геометрию многообразия данных: по её скор-функции строятся римановы метрики на пространстве данных [29], а её детерминированные траектории несут содержательную семантическую информацию об объекте. Детерминированная траектория переводит объект в латентный код, по которому возможны осмысленная интерполяция и редактирование [30; 31], а у предобученной модели вдоль траектории уже существует семантическое латентное пространство [32]. Разные участки траектории, то есть разные масштабы шума, кодируют семантику разного уровня, от грубой структуры до мелких деталей [33]. Каждому объекту x сопоставляется траектория $z_x(\cdot)$ обыкновенного дифференциального уравнения (ОДУ) вероятностного потока, описывающая объект сразу на всех уровнях шума. По таким траекториям строится мера сложности выборки: для неё установлены достаточные условия корректности с точными границами и предложен способ её вычисления. Используемый функционал известен в машинном обучении как информационный выигрыш гауссовского процесса [34; 35]. В настоящей работе он обоснован как мера сложности выборки, снабжён точными границами прироста и реализован через траектории диффузионной модели.

Объект исследования . . . обучающие выборки в задачах машинного обучения.

Предмет исследования . . . меры сложности и разнообразия таких выборок, согласованные с семантической геометрией порождающего распределения.

Цель работы состоит в том, чтобы построить и обосновать меру сложности выборки, учитывающую семантическую геометрию данных. Для достижения цели решаются следующие **задачи**:

1. формализовать понятие выборки и описать требования к мере сложности;
2. построить меру по положительно полуопределённому ядру, доказать её корректность и установить её свойства;
3. предложить реализацию меры через траекторное вложение диффузионной модели и обосновать корректность этой реализации;
4. экспериментально проверить, что мера согласуется с семантическим разнообразием данных.

Методы исследования. Работа опирается на теорию положительно и условно отрицательно определённых ядер и воспроизводящих ядерных гильбертовых пространств, спектральные характеристики ядерных матриц, теорию ОДУ вероятностного потока диффузионных моделей с численным интегрированием траекторий, а также на вычислительный эксперимент на синтетических данных и изображениях.

Вклад работы.

1. Предложено определение меры сложности выборки и сформулированы требования к ней. Показано, что для выборок с повторами монотонность не следует из субаддитивности.
2. Доказаны достаточные условия корректности меры: положительная полуопределённость порождающего ядра гарантирует все требуемые свойства, причём прирост сложности от добавления объекта ограничен с обеих сторон точными границами.
3. Предложен метод оценки сложности на основе траекторного вложения диффузионной модели, действующий в пространстве объектов без

меток, и экспериментально показано, что мера согласуется с семантическим разнообразием данных.

Научная новизна и практическая значимость. Новыми являются: метод оценки сложности выборки на основе траекторий диффузионной модели, действующий в пространстве объектов без меток; теорема о корректности меры с точными двусторонними границами прироста; доказательство корректности траекторной реализации, то есть метричности расстояния между траекториями и положительной полуопределённости порождаемого ядра. Практическая значимость состоит в том, что мера не требует разметки данных и применима для оценки разнообразия наборов данных, для отбора обучающих подвыборок и для сравнения выборок одного объёма, но разного содержания.

Апробация. Основные результаты работы были представлены на 68-й Всероссийской научной конференции МФТИ в секции проблем интеллектуального анализа данных, распознавания и прогнозирования, апрель 2026 г.

Структура работы. В разделе 2 формализуется понятие выборки и вводится мера сложности. В разделе 3 строится мера по положительно полуопределённому ядру, доказываются теоремы о её корректности и свойствах и приводится реализация через траекторное вложение диффузионной модели. Раздел 4 содержит вычислительные эксперименты, а раздел 5 посвящён заключению.

2 Постановка задачи

Определение 2.1. *Распределением данных* называется вероятностная мера p на $\mathbb{R}^d$, абсолютно непрерывная относительно меры Лебега, с плотностью $p(\mathbf{x})$.

Определение 2.2. *Генеральной совокупностью* Γ называется множество $\text{supp } p \subseteq \mathbb{R}^d$.

Гипотеза многообразия. На практике носитель Γ редко заполняет всё пространство $\mathbb{R}^d$. Согласно гипотезе многообразия, высокоразмерные данные сосредоточены вблизи низкоразмерного многообразия, поскольку порождающий их процесс обладает немногими существенными степенями свободы [36;

37]. Эта гипотеза имеет теоретическое обоснование [38] и эмпирические подтверждения, в которых внутренняя размерность типичных наборов изображений оказывается на порядки меньше размерности пикселей [19; 39]. Простой пример многообразия данных даёт орбита одного изображения под действием группы преобразований. Вращения плоскости $SO(2)$ порождают одномерное многообразие, а сдвиги и малые повороты дают многообразие, размерность которого равна числу параметров преобразования и не зависит от размерности d объемлющего пространства. Внутренняя размерность данных обычно много меньше размерности наблюдений d . Поэтому содержательную сложность выборки естественно измерять не размерностью объемлющего пространства и не числом объектов, а числом реально занятых независимых направлений. Эта же картина объясняет, почему сложность быстро насыщается с ростом выборки: новые объекты ложатся в окрестность уже покрытой части многообразия и почти не добавляют новых направлений. Предлагаемая далее мера согласована с этой картиной: траекторное вложение объектов отражает их близость на многообразии данных, а спектр порождаемого ядра подсчитывает эффективное число занятых направлений.

Определение 2.3. *Выборкой* объёма N называется набор объектов

$$X = (\mathbf{x}_1, \dots, \mathbf{x}_N) \in \Gamma^N,$$

возможно с повторами.

Определение 2.4. *Мерой сложности выборки* называется отображение

$$\mu_D : \bigcup_{N \geq 1} \Gamma^N \rightarrow \mathbb{R}_+,$$

определённое на выборках произвольного объёма и удовлетворяющее трём условиям [28]:

(C1) *инвариантность к перестановкам*: для любой перестановки $\pi \in S_N$

$$\mu_D(\mathbf{x}_{\pi(1)}, \dots, \mathbf{x}_{\pi(N)}) = \mu_D(\mathbf{x}_1, \dots, \mathbf{x}_N);$$

(C2) *субаддитивность*: для любых выборок X, Y

$$\mu_D(X \cup Y) \leq \mu_D(X) + \mu_D(Y);$$

(C3) *монотонность*: для любой выборки X и объекта x

$$\mu_D(X) \leq \mu_D(X \cup \{x\}).$$

Условие (C1) означает, что μ_D зависит лишь от объектов выборки, но не от их порядка. Условие (C2) выражает субаддитивность сложности [28], а (C3) требует, чтобы добавление данных не уменьшало сложность. В теории меры для конечных множеств свойство монотонности следует из субаддитивности, однако это не следует в случае если объекты в выборке могут повторяться.

Утверждение 2.5. *Условие (C3) не следует из (C1)–(C2).*

Доказательство.

Доказательство приведено в приложении [A](#). □

3 Предлагаемое решение

В этом разделе мы (§3.1) показываем, что любое положительно полуопределённое ядро с единичной диагональю порождает корректную меру сложности (теорема 3.2). Затем мы пользуемся классическим критерием Шёнберга, который выражает положительную полуопределённость ядра через порождающую его функцию ψ (теорема 3.5). В §3.3 это расстояние строится явно как L^p -метрика, ядро которой положительно полуопределено (теорема 3.6). Наконец (§3.4) расстояние реализуется через траектории диффузионного процесса как частный случай этой схемы.

3.1 Мера сложности и положительно полуопределённые ядра

Обозначим через $\mathcal{X}$ произвольное непустое множество. Оно играет роль генеральной совокупности из определения 2.3, а выборки понимаются так же, возможно с повторами.

Под *ядром* на $\mathcal{X}$ мы, следуя теории положительно и отрицательно определённых функций [40, гл. 3], понимаем произвольную симметричную функцию $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$. Каждой выборке $X = (\mathbf{x}_1, \dots, \mathbf{x}_N)$ ядро сопоставляет симметричную *матрицу ядра* $K(X) = (k(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^N$ своих значений на X .

Определение 3.1. Ядро k называется *положительно полуопределённым* (ППО) [40, гл. 3], если для любого N , любых $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathcal{X}$ и любого $\mathbf{c} \in \mathbb{R}^N$

$$\sum_{i,j=1}^N c_i c_j k(\mathbf{x}_i, \mathbf{x}_j) \geq 0,$$

то есть всякая матрица ядра $K(X)$ положительно полуопределена ($K \succeq 0$). Если $k(\mathbf{x}, \mathbf{x}) = 1$ для всех $\mathbf{x}$, то $K_{ii} = 1$ и $|K_{ij}| \leq 1$.

По ППО-ядру k с $k(\mathbf{x}, \mathbf{x}) = 1$ определяем меру сложности

$$\mu_D(X) = \log \det (I + K(X)). \quad (1)$$

Собственные числа $\nu_1, \dots, \nu_N$ матрицы $K \succeq 0$ неотрицательны, собственные числа матрицы $I + K$ равны $1 + \nu_k$, а её определитель равен их произведению, поэтому

$$\mu_D(X) = \log \prod_{k=1}^N (1 + \nu_k) = \sum_{k=1}^N \log(1 + \nu_k).$$

Для выборок X, Y через $X \cup Y$ обозначаем их конкатенацию (сумму мультимножеств); матрица ядра при этом блочная,

$$K(X \cup Y) = \begin{pmatrix} K(X) & B \\ B^\top & K(Y) \end{pmatrix}, \quad B = (k(\mathbf{x}_i, \mathbf{y}_j)).$$

Теорема 3.2. Пусть k — ППО-ядро на $\mathcal{X}$ с $k(\mathbf{x}, \mathbf{x}) = 1$ для всех $\mathbf{x}$. Тогда μ_D из (1) — мера сложности выборки в смысле определения 2.4 (X в роли Γ), причём для любого $N \geq 1$, любой выборки $X \in \mathcal{X}^N$ и любого объекта $\mathbf{x} \in \mathcal{X}$ верно неравенство:

$$\log \frac{N+2}{N+1} \leq \mu_D(X \cup (\mathbf{x})) - \mu_D(X) \leq \log 2;$$

в частности, прирост всегда строго положителен.

Доказательство.

Доказательство приведено в приложении А. □

Для одиночного объекта $K((\mathbf{x})) = (1)$ и $\mu_D((\mathbf{x})) = \log 2$: нормировка $k(\mathbf{x}, \mathbf{x}) = 1$ фиксирует сложность отдельно взятого объекта. Верхняя граница означает, что новый объект не может добавить к сложности выборки больше собственной сложности $\log 2$. Максимальный прирост $\log 2$ достигается в точности тогда, когда новый объект ортогонален всем объектам выборки в признаковом пространстве ядра, то есть когда $k(\mathbf{x}, \mathbf{x}_i) = 0$ для всех i . Такой объект не объясняется уже имеющимися наблюдениями и потому несёт максимум новой информации.

Нижняя граница показывает, что даже точная копия уже имеющегося объекта строго увеличивает сложность, но лишь на величину порядка $1/N$. Повторы быстро обесцениваются. Граница неуплучшаема. Худший случай это выборка из N копий одного объекта, для которой K — матрица из единиц со спектром $(N + 1, 1, \dots, 1)$, так что $\mu_D = \log(N + 1)$, и каждая следующая копия добавляет ровно $\log \frac{N+2}{N+1}$.

У этого крайнего случая есть теоретико-информационный смысл. Выборка из N копий одного объекта несёт информацию только о числе повторов, а её содержание исчерпывается одним объектом. Величина $\log(N + 1)$ по порядку совпадает с количеством информации, необходимым, чтобы закодировать целое число от 0 до N , то есть записать размер выборки: на счётчик кратности требуется $\Theta(\log N)$ нат. На полностью вырожденной выборке мера вырождается в информацию об одном лишь её объёме. Для сравнения, разнообразная выборка добавляет до $\log 2$ нат на каждый новый независимый объект и тем самым кодирует содержание, а не только размер.

Следствие 3.3. *Отображение $S \mapsto \log \det(I + K(S))$ субмодулярно: для $A \subseteq B$ и объекта $\mathbf{x}$*

$$\mu_D(A \cup (\mathbf{x})) - \mu_D(A) \geq \mu_D(B \cup (\mathbf{x})) - \mu_D(B).$$

Доказательство.

Доказательство приведено в приложении А. □

Субмодулярность означает, что скорость роста сложности убывает: чем больше выборка, тем меньше прирост от добавления нового объекта. У этого

есть наглядная вероятностная интерпретация. Если рассматривать k как ковариацию гауссовского процесса, то прирост сложности связан с апостериорной дисперсией предсказания в новой точке по уже имеющейся выборке. Добавление наблюдений эту дисперсию не увеличивает, поэтому ценность каждого следующего объекта тем меньше, чем больше похожих на него объектов уже есть.

3.2 Критерий положительной определённости ядра

Теорема 3.2 требует ППО-ядра. Опишем, когда оно таково. Ядра вида $k = e^{-\lambda\psi}$ строятся по симметричной функции ψ , и критерий формулируется в терминах условной отрицательной определённости.

Определение 3.4. Ядро ψ называется *условно отрицательно определённым* (УОО) [40, гл. 3], если для любого N , любых $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathcal{X}$ и любого $\mathbf{c} \in \mathbb{R}^N$ с $\sum_i c_i = 0$

$$\sum_{i,j} c_i c_j \psi(\mathbf{x}_i, \mathbf{x}_j) \leq 0.$$

Следующий критерий принадлежит Шёнбергу. Систематическое изложение теории дано в [40, гл. 3].

Теорема 3.5. Для симметричного ψ с $\psi(\mathbf{x}, \mathbf{x}) = 0$ эквивалентны:

- (i) ψ условно отрицательно определено;
- (ii) ядро $e^{-\lambda\psi}$ положительно полуопределено при всех $\lambda > 0$;
- (iii) существуют гильбертово пространство $\mathcal{H}$ и отображение $\Phi : \mathcal{X} \rightarrow \mathcal{H}$ с $\psi(\mathbf{x}, \mathbf{y}) = \|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|_{\mathcal{H}}^2$.

Более того, если ψ УОО, то ψ^α УОО при всех $\alpha \in (0, 1]$, и эта граница точна.

Теоремы 3.2 и 3.5 вместе дают целый класс мер сложности. Каждая УОО-функция ψ с нулевой диагональю и каждая пара параметров $\lambda > 0$, $\alpha \in (0, 1]$ порождают корректную меру $\mu_D(X) = \log \det (I + (e^{-\lambda\psi^\alpha(\mathbf{x}_i, \mathbf{x}_j)}))$. Единственная содержательная степень свободы конструкции состоит в выборе функции ψ , которая должна задавать семантическую отдалённость объектов. Для семантически близких объектов $\psi \approx 0$ и ядро $e^{-\lambda\psi} \approx 1$, так что

такая пара почти не увеличивает сложность по сравнению с одним объектом. Для семантически далёких объектов ψ велико, ядро близко к нулю, и вклады объектов складываются как независимые, по $\log 2$ на объект (теорема 3.2).

Пункт (iii) теоремы 3.5 даёт геометрическую интерпретацию допустимых функций. Функция ψ УОО в точности тогда, когда $\psi(\mathbf{x}, \mathbf{y}) = \|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|_{\mathcal{H}}^2$ для некоторого вложения Φ в гильбертово пространство. Иными словами, выбрать ψ то же самое, что выбрать представление объектов точками гильбертова пространства, в котором семантическая отдалённость измеряется метрикой этого пространства. Допустимы все способы спрямить семантику в гильбертову геометрию, и только они. Ядро $k = e^{-\lambda\|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|^2}$ является при этом гауссовым ядром в пространстве представлений. Параметр λ задаёт масштаб, на котором различия представлений считаются существенными, а μ_D считает эффективное число различимых на этом масштабе представлений.

3.3 Условно отрицательно определённые расстояния в L^p

В этом разделе обобщается теорема [41] на векторозначные функции, которые будут использоваться нами далее.

Теорема 3.6. Пусть (T, w) — пространство с мерой, $p \in (0, 2]$, $\beta \in (0, 2]$, $\lambda > 0$, и отображение $x \mapsto \varphi_x \in L^p(T, w; \mathbb{R}^d)$ инъективно. Тогда

$$D(x, y) = \left(\int_T \|\varphi_x(t) - \varphi_y(t)\|^p w(t) dt \right)^{1/2}$$

является метрикой, а ядро $k(x, y) = e^{-\lambda D(x, y)^\beta}$ положительно полуопределено.

Доказательство.

Доказательство приведено в приложении A. □

При $p < 1$ пространство $L^p(T, w; \mathbb{R}^d)$ не является гильбертовым и даже нормированным: для $(\int_T \|\cdot\|^p w)^{1/p}$ нарушается неравенство треугольника. Поэтому мы рассматриваем его просто как множество, на котором заданы отображения φ_x , а метричность D обеспечивается не структурой L^p , а гильбертовым вложением из теоремы 3.5. Условия $p \in (0, 2]$ и $\beta \in (0, 2]$ точны [42—44]. При $\beta = 2$ ядро $e^{-\lambda D^2}$ гауссово (квадрат расстояния), а при $\beta = 1$ ядро $e^{-\lambda D}$ лапласово.

3.4 Реализация: траекторное вложение

Диффузионная модель описывает данные семейством зашумлённых распределений p_t , которые получаются добавлением к исходному распределению p гауссова шума возрастающей дисперсии. Порождение объектов сводится к обращению этого процесса. У стохастического зашумления есть детерминированный аналог, ОДУ вероятностного потока: его траектории имеют те же одномерные распределения p_t , что и стохастический процесс [45]. Эти детерминированные траектории и служат вложением объектов.

Осталось задать функцию ψ . Каждому объекту $\mathbf{x}$ сопоставим детерминированную траекторию $t \mapsto \mathbf{z}_{\mathbf{x}}(t)$ ОДУ вероятностного потока, ассоциированного с диффузионной моделью, и положим ψ равным квадрату нормы разности траекторий в $L^2([0, 1], \mu_w; \mathbb{R}^d)$.

Траектория задаётся скор-функцией распределения. Скор-функция — $\nabla_{\mathbf{x}} \ln p_t(\mathbf{x})$, где зашумлённое распределение p_t получается свёрткой p с гауссовым ядром:

$$p_t(\mathbf{x}) = (p * \mathcal{N}(\mathbf{0}, \sigma^2(t)\mathbf{I}))(\mathbf{x}) = \int_{\mathbb{R}^d} p(\mathbf{y}) \frac{1}{(2\pi\sigma^2(t))^{d/2}} \exp\left(-\frac{\|\mathbf{x} - \mathbf{y}\|^2}{2\sigma^2(t)}\right) d\mathbf{y}, \quad (2)$$

$\sigma : [0, 1] \rightarrow \mathbb{R}_+$ монотонно возрастает, $\sigma(0) = 0$. Скор-функции отвечает детерминированное ОДУ вероятностного потока [46, (20.57)]:

$$\frac{d\mathbf{z}}{dt} = -\sigma(t)\dot{\sigma}(t)\mathbf{s}(\mathbf{z}(t), t), \quad \mathbf{z}_{\mathbf{x}}(0) = \mathbf{x}, \quad (3)$$

где $\mathbf{s}(\mathbf{z}, t)$ — скор-поле: истинная скор-функция $\nabla_{\mathbf{z}} \ln p_t(\mathbf{z})$, задающая идеальную меру, либо — на практике обученная диффузионная модель $\mathbf{s}_{\theta}(\mathbf{z}, t) \approx \nabla_{\mathbf{z}} \ln p_t(\mathbf{z})$ с параметрами θ , дающая вычислимую аппроксимацию меры.

Предположение 3.7. Скор-поле $\mathbf{s}(\cdot, t)$ в (3) липшицево по первому аргументу с константой L , равномерной по $t \in [0, 1]$, и непрерывно по t ; функция σ непрерывно дифференцируема.

При предположении 3.7 правая часть (3) непрерывна и глобально липшицева по $\mathbf{z}$ равномерно по t , поэтому задача Коши имеет единственное решение, продолжаемое на весь отрезок $[0, 1]$ (теорема Пикара–Линделёфа, [47, гл. 2]): каждый объект $\mathbf{x}$ задаёт единственную траекторию $\mathbf{z}_{\mathbf{x}}(t)$, а вложение

$\Phi(\mathbf{x}) = \mathbf{z}_x(\cdot)$ определено корректно.

Несходство объектов определяем как взвешенный квадрат L^2 -нормы между траекториями:

$$D(\mathbf{x}_i, \mathbf{x}_j)^2 = \int_0^1 \|\mathbf{z}_{\mathbf{x}_i}(t) - \mathbf{z}_{\mathbf{x}_j}(t)\|^2 w(t) dt, \quad w(t) = \text{Beta}(t; a, b), \quad (4)$$

то есть квадрат нормы в $L^2([0, 1], \mu_w; \mathbb{R}^d)$ с мерой $d\mu_w(t) = w(t) dt$.

Выбор траекторного вложения мотивирован двумя соображениями. *Мультимасштабность*: вдоль траектории уровень шума $\sigma(t)$ пробегает все значения от 0 до $\sigma(1)$, поэтому расстояние (4) агрегирует различия объектов сразу на всех масштабах. От тонкой локальной структуры при малых t до взаимного расположения крупных мод распределения при больших. Вес w задаёт вклад каждого масштаба. *Общность*: вложения по отдельному моменту времени — предельный случай конструкции: при слабой сходимости μ_w к точечной мере δ_{t_0} расстояние (4) переходит в $\|\mathbf{z}_{\mathbf{x}_i}(t_0) - \mathbf{z}_{\mathbf{x}_j}(t_0)\|^2$ (подынтегральная функция непрерывна и ограничена), а семейство $\text{Beta}(t; a, b)$ содержит и равномерный вес ($a = b = 1$), и сколь угодно острые приближения δ_{t_0} для любого $t_0 \in (0, 1)$.

Расстояние (4) по своей сути представляет из себя квадрат нормы в гильбертовом пространстве траекторий $\mathcal{H} = L^2([0, 1], \mu_w; \mathbb{R}^d)$; объект $\mathbf{x}$ вкладывается в него траекторией $\Phi(\mathbf{x}) = \mathbf{z}_x(\cdot)$. Следующее утверждение формально переносит УОО-свойство с пространства траекторий на объекты выборки.

Утверждение 3.8. При предположении 3.7 функция $D^2 : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ из (4) симметрична, имеет нулевую диагональ и условно отрицательно определена на $\mathbb{R}^d$; то же верно для всех степеней D^β , $\beta \in (0, 2]$.

Итоговая мера сложности выборки $X = (\mathbf{x}_1, \dots, \mathbf{x}_N)$:

$$\mu_D(X) = \log \det \left(I + \left(e^{-\lambda D^2(\mathbf{x}_i, \mathbf{x}_j)} \right)_{i,j=1}^N \right), \quad (5)$$

По утверждению 3.8 годится и любая степень D^β , $\beta \in (0, 2]$: гауссово ядро (5) отвечает $\beta = 2$, лапласово $e^{-\lambda D} \beta = 1$. Случаи $\beta \leq 1$ выделяются дополнительным структурным свойством: ядро становится метрикой подобия.

Определение 3.9. Метрикой подобия (similarity metric) [41; 48] на множестве X называется функция $s : X \times X \rightarrow \mathbb{R}$ такая, что для всех $\mathbf{x}, \mathbf{y}, \mathbf{z} \in X$

$$(s1) \ s(\mathbf{x}, \mathbf{y}) = s(\mathbf{y}, \mathbf{x});$$

$$(s2) \ s(\mathbf{x}, \mathbf{x}) \geq 0;$$

$$(s3) \ s(\mathbf{x}, \mathbf{x}) \geq s(\mathbf{x}, \mathbf{y});$$

$$(s4) \ s(\mathbf{x}, \mathbf{y}) + s(\mathbf{y}, \mathbf{z}) \leq s(\mathbf{x}, \mathbf{z}) + s(\mathbf{y}, \mathbf{y});$$

$$(s5) \ s(\mathbf{x}, \mathbf{x}) = s(\mathbf{y}, \mathbf{y}) = s(\mathbf{x}, \mathbf{y}) \iff \mathbf{x} = \mathbf{y}.$$

Метрика подобия *нормирована*, если $s \geq 0$ и $s(\mathbf{x}, \mathbf{x}) = 1$ для всех $\mathbf{x}$.

Замечание 3.10. При $\beta \in (1, 2]$ ядро $e^{-\lambda D^\beta}$ остаётся ППО, но свойство метрики подобия в общем случае теряется. Уже для евклидова расстояния на прямой гауссово ядро $s = e^{-\lambda|x-y|^2}$ нарушает условие (s4) на тройке $x = 0$, $y = \varepsilon$, $z = 2\varepsilon$:

$$s(x, y) + s(y, z) = 2e^{-\lambda\varepsilon^2} = 2 - 2\lambda\varepsilon^2 + O(\varepsilon^4) > 2 - 4\lambda\varepsilon^2 + O(\varepsilon^4) = 1 + e^{-4\lambda\varepsilon^2} = s(x, z) + s(y, y),$$

при достаточно малом ε .

Завершим количественной проверкой устойчивости: мера липшицево зависит и от объектов выборки, и от скор-поля; вторая оценка обосновывает замену истинного сора обученным.

Утверждение 3.11. Пусть выполнено предположение 3.7, $\lambda > 0$, L — константа Липшица поля $\mathbf{s}$, $C = \sup_{t \in [0,1]} \sigma(t) \dot{\sigma}(t) < \infty$, и μ_D — мера (5). Тогда:

(i) для любых $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^d$ вложение Φ липшицево: $\|\Phi(\mathbf{x}) - \Phi(\mathbf{x}')\|_{\mathcal{H}} \leq e^{CL} \|\mathbf{x} - \mathbf{x}'\|$;

(ii) для любой выборки X объёма N , индекса $k \in \{1, \dots, N\}$ и объекта $\mathbf{x}'_k \in \mathbb{R}^d$: если X' получена из X заменой $\mathbf{x}_k \mapsto \mathbf{x}'_k$, то

$$|\mu_D(X') - \mu_D(X)| \leq 2N\sqrt{2\lambda/e} e^{CL} \|\mathbf{x}_k - \mathbf{x}'_k\|;$$

(iii) если поле $\widehat{\mathbf{s}}$ также удовлетворяет предположению 3.7 и $\sup_{\mathbf{z}, t} \|\mathbf{s}(\mathbf{z}, t) - \widehat{\mathbf{s}}(\mathbf{z}, t)\| \leq \varepsilon$, то для меры $\widehat{\mu}_D$, построенной по полю $\widehat{\mathbf{s}}$,

$$|\mu_D(X) - \widehat{\mu}_D(X)| \leq 2N^2\sqrt{2\lambda/e} C e^{CL} \varepsilon.$$

Доказательство.

Доказательство приведено в приложении [А](#).

□

4 Вычислительные эксперименты

Эксперименты проверяют три группы утверждений: алгебраические свойства меры на контролируемых данных, способность траекторного вложения различать семантически разные выборки там, где поточечные представления этого не позволяют, и согласованность меры с разнообразием на реальных изображениях. Код экспериментов и инструкции по воспроизведению приведены в репозитории работы.

4.1 Алгебраические свойства

На синтетических выборках с аналитически заданными ядрами проверяются свойства меры из раздела [3](#): инвариантность к перестановкам, субаддитивность, монотонность с точными границами $\log \frac{N+2}{N+1} \leq \Delta \leq \log 2$, субмодулярность, а также крайние случаи (выборка из копий одного объекта и набор ортогональных объектов). Проверки выполняются с контролем численной точности.

4.2 Поточечное вложение и его ограничения

На смесях гауссиан с известной скор-функцией строится вложение по значению скор-функции в один момент времени. Локальность скор-функции приводит к тому, что разрешённые моды смеси оказываются почти неразличимы по такому вложению. Этот эффект мотивирует переход к траекторному вложению, использующему всю траекторию порождающего процесса.

4.3 Траекторное вложение

Для траекторного вложения измеряются скорость роста μ_D с объёмом выборки для выборок разной степени разнообразия, разделение кластеров и оценка внутренней размерности. Рис. [1](#) показывает, что для разнообразных выборок μ_D растёт быстрее, чем для выборок с близкими по смыслу объектами.




Рис. 1: Рост меры сложности $\mu_D(X)$ с объёмом выборки N для выборок разной структуры. Синяя кривая: каждый объект образует новый независимый кластер, сложность растёт по верхней границе $N \log 2$. Оранжевая и зелёная: все объекты из одного кластера с разбросом $\sigma = 1$ и $\sigma = 0,1$ соответственно; для плотного кластера рост выходит на нижнюю границу $\log(1 + N)$. Пунктиром показаны теоретические границы прироста.

4.4 Изображения MNIST

На предобученной диффузионной модели для изображений MNIST траектории вычисляются численным интегрированием ОДУ вероятностного потока. Рис. 2 показывает, что мера согласована с семантическим разнообразием: выборка из изображений одного класса (цифры 0) растёт с объёмом медленнее, чем выборка из изображений разных классов. Отдельно проверяется выборка-орбита: набор из малых сдвигов и поворотов одного изображения при большом числе объектов остаётся низкосложным.

5 Заключение

В работе предложена и обоснована мера сложности обучающей выборки, учитывающая семантическую геометрию данных, которая извлекается из предобученной диффузионной модели. Поставленные задачи решены.

Формализовано понятие выборки, упорядоченной и допускающей повторы, и описаны требования к мере сложности: инвариантность к перестановкам, субаддитивность и монотонность. Показано, что для выборок с по-




Рис. 2: Рост меры сложности $\mu_D(X)$ с объёмом выборки N на изображениях MNIST. Выборка из изображений одного класса (цифра 0) имеет меньшую сложность, чем выборка из изображений разных классов.

вторыми монотонность не вытекает из субаддитивности и является самостоятельным требованием.

Доказана теорема о достаточном условии корректности: для всякого положительно полуопределённого ядра с единичной диагональю мера $\mu_D(X) = \log \det(I + K)$ обладает всеми тремя свойствами, причём прирост сложности при добавлении объекта ограничен с обеих сторон точными границами $\log \frac{N+2}{N+1} \leq \Delta \leq \log 2$. Установлены дополнительные свойства меры, включая субмодулярность, а критерий Шёнберга описывает, какие ядра порождают корректную меру.

Предложена реализация меры через траекторное вложение диффузионной модели. Каждому объекту сопоставляется траектория ОДУ вероятностного потока, расстояние между траекториями D является метрикой при $p \in (0, 2]$, а порождаемое ядро $e^{-\lambda D^p}$ положительно полуопределено. Доказана липшицева устойчивость меры к возмущению скор-функции. Вычислительные эксперименты показали, что мера растёт вместе с семантическим разнообразием данных на синтетических наборах и на изображениях MNIST.

Практическая значимость состоит в том, что мера не требует разметки данных и снабжена доказанными гарантиями корректности. Она применима к оценке разнообразия наборов данных, к отбору обучающих подвыборок и к сравнению выборок одного объёма, но разного содержания. По форме мера принадлежит семейству спектральных мер разнообразия и совпадает

с информационным выигрышем гауссовского процесса. В настоящей работе этот функционал обоснован как мера сложности выборки, снабжён точными границами прироста и реализован через траектории диффузионной модели.

План дальнейших исследований.

- *Асимптотика меры.* Скорость роста $\mu_D(X)$ при $N \rightarrow \infty$ определяется скоростью убывания спектра ядерного интегрального оператора и, как следствие, внутренней размерностью носителя распределения; представляет интерес строгое описание этой связи и режимов с согласованным масштабом $\lambda = \lambda_N$.
- *Обоснованный выбор полосы λ .* Переход от калибровки на эталонной выборке к адаптивному выбору масштаба непосредственно по данным.
- *Масштабирование.* Применение к крупным предобученным диффузионным моделям и другим модальностям (текст, аудио), а также вычислительно эффективная аппроксимация $\log \det$ больших ядерных матриц (методы Нистрёма, случайные проекции).
- *Связь с обобщением.* Установление границ, связывающих μ_D с эффективностью обучения и обобщающей способностью моделей.

А Доказательства

Доказательство теоремы 3.6.

Обозначим $D(x, y)^2 = \int_T \|\varphi_x(t) - \varphi_y(t)\|^p w(t) dt$.

Условная отрицательная определённость D^2 . При каждом t функция $(x, y) \mapsto \|\varphi_x(t) - \varphi_y(t)\|^p = (\|\varphi_x(t) - \varphi_y(t)\|^2)^{p/2}$ условно отрицательно определена: квадрат евклидовой нормы УОО (теорема 3.5(iii)), а показатель $p/2 \leq 1$ сохраняет УОО (теорема 3.5, часть о степенях). Интегрирование с весом $w \geq 0$ сохраняет УОО: при $\sum_i c_i = 0$

$$\sum_{i,j} c_i c_j D(x_i, x_j)^2 = \int_T \left(\sum_{i,j} c_i c_j \|\varphi_{x_i}(t) - \varphi_{x_j}(t)\|^p \right) w(t) dt \leq 0,$$

так как подынтегральная сумма неположительна при каждом t . Значит D^2 условно отрицательно определена, симметрична и имеет нулевую диагональ.

Метричность D . По теореме 3.5(iii), применённой к D^2 , существуют гильбертово пространство $\mathcal{H}$ и отображение $\Psi : x \mapsto \Psi(x) \in \mathcal{H}$ с $D(x, y)^2 = \|\Psi(x) - \Psi(y)\|_{\mathcal{H}}^2$, то есть $D(x, y) = \|\Psi(x) - \Psi(y)\|_{\mathcal{H}}$. Отсюда симметрия, неотрицательность и неравенство треугольника. Наконец, $D(x, y) = 0$ равносильно $\varphi_x = \varphi_y$ (w -почти всюду), а в силу инъективности отображения $x \mapsto \varphi_x$ это равносильно $x = y$. Значит D — метрика.

Положительная полуопределённость ядра. Так как D^2 условно отрицательно определена и $\beta/2 \leq 1$, степень $D^\beta = (D^2)^{\beta/2}$ также условно отрицательно определена (теорема 3.5, часть о степенях). По теореме 3.5(ii) ядро $e^{-\lambda D^\beta}$ положительно полуопределено при всех $\lambda > 0$. $\square$

Доказательство утверждения 2.5.

Рассмотрим меру $\mu_D(X) = f(|X|)$, зависящую только от объёма выборки, где $f(0) = 0$, $f(1) = 2$ и $f(n) = 1$ при $n \geq 2$. Она удовлетворяет (C1), так как зависит лишь от $|X|$, и (C2), так как $f(m+n) \leq f(m) + f(n)$ для всех $m, n \geq 0$. Однако $f(2) = 1 < 2 = f(1)$, таким образом добавление второго объекта уменьшает сложность. Условие (C3) нарушено. $\square$

Доказательство теоремы 3.2.

Матрица $K = K(X)$ положительно полуопределена (определение 3.1), поэтому $I + K \succ 0$ и μ_D определена и неотрицательна.

(C1) Перестановка π объектов заменяет K на $PKP^\top$ с матрицей перестановки P , и $\det(I + PKP^\top) = \det(P(I + K)P^\top) = \det(I + K)$, так что μ_D не меняется.

(C2) Матрица $M = I + K(X \cup Y) = \begin{pmatrix} A & B \\ B^\top & C \end{pmatrix}$ с $A = I + K(X) \succ 0$, $C = I + K(Y) \succ 0$ положительно определена. По формуле дополнения Шура $\det M = \det A \cdot \det(C - B^\top A^{-1}B)$. Так как $B^\top A^{-1}B \succeq 0$, то $0 \prec C - B^\top A^{-1}B \preceq C$; определитель монотонен на конусе положительно определённых матриц ($0 \prec S \preceq C \Rightarrow \det S \leq \det C$, по теореме Вейля о собственных числах), поэтому $\det M \leq \det A \cdot \det C$ (неравенство Фишера, см. [49, §7.8]). Логарифмируя, получаем $\mu_D(X \cup Y) \leq \mu_D(X) + \mu_D(Y)$.

(C3) Пусть $\mathbf{b} = (k(\mathbf{x}, \mathbf{x}_i))_{i=1}^N$. С учётом $k(\mathbf{x}, \mathbf{x}) = 1$

$$I + K(X \cup (\mathbf{x})) = \begin{pmatrix} I+K & \mathbf{b} \\ \mathbf{b}^\top & 2 \end{pmatrix},$$

дополнение Шура к блоку $I + K$ равно $s = 2 - \mathbf{b}^\top (I + K)^{-1} \mathbf{b}$, и

$$\Delta := \mu_D(X \cup (\mathbf{x})) - \mu_D(X) = \log s.$$

Верхняя граница. Так как $(I + K)^{-1} \succ 0$, то $\mathbf{b}^\top (I + K)^{-1} \mathbf{b} \geq 0$, откуда $s \leq 2$ и $\Delta \leq \log 2$.

Нижняя граница. Матрица $\begin{pmatrix} K & \mathbf{b} \\ \mathbf{b}^\top & 1 \end{pmatrix} = K(X \cup (\mathbf{x})) \succeq 0$, поэтому для всех $\mathbf{u} \in \mathbb{R}^N$, $t \in \mathbb{R}$ выполнено $\mathbf{u}^\top K \mathbf{u} + 2t \mathbf{b}^\top \mathbf{u} + t^2 \geq 0$; минимизация по t даёт $(\mathbf{b}^\top \mathbf{u})^2 \leq \mathbf{u}^\top K \mathbf{u}$ для всех $\mathbf{u}$. Положим $\mathbf{v} = (I + K)^{-1} \mathbf{b}$. Тогда

$$q := \mathbf{b}^\top (I + K)^{-1} \mathbf{b} = \mathbf{v}^\top (I + K) \mathbf{v} = \|\mathbf{v}\|^2 + \mathbf{v}^\top K \mathbf{v},$$

а из предыдущего неравенства при $\mathbf{u} = \mathbf{v}$ имеем $q^2 = (\mathbf{b}^\top \mathbf{v})^2 \leq \mathbf{v}^\top K \mathbf{v} = q - \|\mathbf{v}\|^2$. Нормировка ядра, применённая к расширенной выборке $X \cup (\mathbf{x})$, даёт $|b_i| \leq 1$ (определение 3.1), откуда $\|\mathbf{b}\|^2 \leq N$; по неравенству Коши–Буняковского $q = \mathbf{b}^\top \mathbf{v} \leq \|\mathbf{b}\| \|\mathbf{v}\| \leq \sqrt{N} \|\mathbf{v}\|$, то есть $\|\mathbf{v}\|^2 \geq q^2/N$. Подставляя, получаем $q^2 \leq q - q^2/N$, откуда

$$q \leq \frac{N}{N+1}, \quad \Delta = \log(2 - q) \geq \log\left(2 - \frac{N}{N+1}\right) = \log \frac{N+2}{N+1} > 0.$$

□

Доказательство следствия 3.3.

Зафиксируем объект $\mathbf{x}$. Как в доказательстве теоремы 3.2, пункт (С3), прирост сложности при добавлении $\mathbf{x}$ к подвыборке S равен

$$\Delta_S := \mu_D(S \cup (\mathbf{x})) - \mu_D(S) = \log s_S, \quad s_S = 2 - \mathbf{b}_S^\top (I + K(S))^{-1} \mathbf{b}_S,$$

где $\mathbf{b}_S = (k(\mathbf{x}, \mathbf{s}))_{\mathbf{s} \in S}$ и учтено $k(\mathbf{x}, \mathbf{x}) = 1$. Так как $\log$ монотонен, утверждение равносильно неравенству $s_B \leq s_A$ при $A \subseteq B$: достаточно показать, что величина s_S не возрастает при расширении подвыборки.

Матрица $K(B \cup (\mathbf{x}))$ положительно полуопределена, поэтому допускает грам-разложение: найдутся векторы $\{\phi_{\mathbf{s}}\}_{\mathbf{s} \in B}$ и $\phi_{\mathbf{x}}$ в некотором евклидовом пространстве, для которых $\langle \phi_{\mathbf{u}}, \phi_{\mathbf{v}} \rangle = k(\mathbf{u}, \mathbf{v})$ (это канонический признаковый отображатель воспроизводящего ядерного гильбертова пространства, [50]); в частности $\|\phi_{\mathbf{x}}\|^2 = k(\mathbf{x}, \mathbf{x}) = 1$. Введём на $\mathbb{R}^B$ функционал

$$F(\mathbf{w}) = 1 + \|\mathbf{w}\|^2 + \left\| \phi_{\mathbf{x}} - \sum_{\mathbf{s} \in B} w_{\mathbf{s}} \phi_{\mathbf{s}} \right\|^2.$$

Дополнение Шура s_S обладает вариационным представлением

$$s_S = \min_{\mathbf{w} \in \mathbb{R}^S} \left(2 - 2 \mathbf{b}_S^\top \mathbf{w} + \mathbf{w}^\top (I + K(S)) \mathbf{w} \right) = \min_{\text{supp } \mathbf{w} \subseteq S} F(\mathbf{w}),$$

где первый минимум достигается в $\mathbf{w}^* = (I + K(S))^{-1} \mathbf{b}_S$, а второе равенство получается подстановкой $k(\mathbf{x}, \mathbf{x}) = 1$ и тождества $\mathbf{w}^\top K(S) \mathbf{w} - 2 \mathbf{b}_S^\top \mathbf{w} = \left\| \phi_{\mathbf{x}} - \sum_{\mathbf{s} \in S} w_{\mathbf{s}} \phi_{\mathbf{s}} \right\|^2 - 1$.

Пусть $A \subseteq B$. Минимум, задающий s_A , берётся по векторам с носителем в A , а минимум для s_B — по всем $\mathbf{w} \in \mathbb{R}^B$, то есть по более широкому множеству при том же F . Поэтому

$$s_B = \min_{\mathbf{w} \in \mathbb{R}^B} F(\mathbf{w}) \leq \min_{\text{supp } \mathbf{w} \subseteq A} F(\mathbf{w}) = s_A,$$

откуда $\Delta_B = \log s_B \leq \log s_A = \Delta_A$. □

Доказательство утверждения 3.11.

Шаг 1: оценки траекторий. Для двух начальных условий $\mathbf{x}, \mathbf{x}'$ разность

траекторий $\delta(t) = \mathbf{z}_x(t) - \mathbf{z}_{x'}(t)$ в силу интегральной формы (3) удовлетворяет $\|\delta(t)\| \leq \|\mathbf{x} - \mathbf{x}'\| + CL \int_0^t \|\delta(\tau)\| d\tau$, откуда по неравенству Гронуолла $\|\delta(t)\| \leq e^{CLt} \|\mathbf{x} - \mathbf{x}'\|$. Так как μ_w — вероятностная мера, отсюда $\|\Phi(\mathbf{x}) - \Phi(\mathbf{x}')\|_{\mathcal{H}}^2 = \int_0^1 \|\delta(t)\|^2 d\mu_w(t) \leq e^{2CL} \|\mathbf{x} - \mathbf{x}'\|^2$, то есть (i). Аналогично для двух полей при общем начальном условии: разность $\widehat{\delta}(t) = \mathbf{z}_x(t) - \widehat{\mathbf{z}}_x(t)$ удовлетворяет

$$\|\widehat{\delta}(t)\| \leq C \int_0^t (L\|\widehat{\delta}(\tau)\| + \varepsilon) d\tau \leq C\varepsilon t + CL \int_0^t \|\widehat{\delta}(\tau)\| d\tau,$$

и по неравенству Гронуолла $\|\widehat{\delta}(t)\| \leq C\varepsilon t e^{CLt} \leq C\varepsilon e^{CL}$; значит $\|\Phi(\mathbf{x}) - \widehat{\Phi}(\mathbf{x})\|_{\mathcal{H}} \leq C\varepsilon e^{CL}$ для всех $\mathbf{x}$.

Шаг 2: от ядра к мере. Для ППО-матриц K, K' с единичной диагональю

$$|\log \det(I + K') - \log \det(I + K)| \leq \sum_{i \neq j} |K'_{ij} - K_{ij}|.$$

Действительно, отрезок $K_\tau = K + \tau\Delta$, $\Delta = K' - K$, $\tau \in [0, 1]$, лежит в выпуклом конусе ППО-матриц, поэтому $I + K_\tau \succeq I$ обратима, функция $f(\tau) = \log \det(I + K_\tau)$ дифференцируема и $f'(\tau) = \text{tr}((I + K_\tau)^{-1}\Delta) = \sum_{i,j} [(I + K_\tau)^{-1}]_{ji} \Delta_{ij}$. Каждый элемент матрицы не превосходит её спектральной нормы, а $\|(I + K_\tau)^{-1}\| \leq 1$ из $I + K_\tau \succeq I$; так как $\Delta_{ii} = 0$, получаем $|f'(\tau)| \leq \sum_{i \neq j} |\Delta_{ij}|$, и остаётся применить теорему Лагранжа.

Шаг 3: от расстояний к ядру. Функция $u \mapsto e^{-\lambda u^2}$ липшицева на $[0, \infty)$ с константой $\sup_{u \geq 0} 2\lambda u e^{-\lambda u^2} = \sqrt{2\lambda/e}$, а по обратному неравенству треугольника в $\mathcal{H}$ изменение расстояния D не превосходит суммарного сдвига вложений его аргументов. При замене $\mathbf{x}_k \mapsto \mathbf{x}'_k$ меняются лишь $2(N-1)$ внедиагональных записей ядра, каждая — не более чем на $\sqrt{2\lambda/e} e^{CL} \|\mathbf{x}_k - \mathbf{x}'_k\|$ по шагу 1, что вместе с шагом 2 даёт (ii). При замене поля каждое из $N(N-1)$ внедиагональных расстояний меняется не более чем на $2C\varepsilon e^{CL}$ (сдвигаются вложения обоих аргументов, шаг 1), диагональ ядра остаётся единичной, и шаг 2 даёт (iii). $\square$

Список литературы

1. Towards Bridging Sample Complexity and Model Capacity / S. Mei [и др.] // Proceedings of the AAAI Conference on Artificial Intelligence. — 2022. — Т. 36, № 2. — С. 1972—1980. — DOI: [10.1609/aaai.v36i2.20092](https://doi.org/10.1609/aaai.v36i2.20092).
2. Konz N., Mazurowski M. A. The Effect of Intrinsic Dataset Properties on Generalization: Unraveling Learning Differences Between Natural and Medical Images // The Twelfth International Conference on Learning Representations (ICLR 2024). — 2024. — arXiv: [2401.08865](https://arxiv.org/abs/2401.08865) [cs.CV].
3. Chen S., Dobriban E., Lee J. H. A Group-Theoretic Framework for Data Augmentation // Journal of Machine Learning Research. — 2020. — Т. 21, № 245. — С. 1—71. — URL: <https://jmlr.org/papers/v21/20-163.html>.
4. Scaling Laws for Neural Language Models / J. Kaplan [и др.] // arXiv preprint arXiv:2001.08361. — 2020. — arXiv: [2001.08361](https://arxiv.org/abs/2001.08361) [cs.LG].
5. Sub-Scaling Laws: On the Role of Data Density and Training Strategies in LLMs / Z. Chen [и др.] // arXiv preprint arXiv:2507.10613. — 2025. — arXiv: [2507.10613](https://arxiv.org/abs/2507.10613) [cs.LG].
6. Deduplicating Training Data Makes Language Models Better / K. Lee [и др.] // Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) / под ред. S. Muresan, P. Nakov, A. Villavicencio. — Dublin, Ireland : Association for Computational Linguistics, 05.2022. — С. 8424—8445. — DOI: [10.18653/v1/2022.acl-long.577](https://doi.org/10.18653/v1/2022.acl-long.577).
7. Beyond neural scaling laws: beating power law scaling via data pruning / B. Sorscher [и др.] // Advances in Neural Information Processing Systems. Т. 35 / под ред. S. Koyejo [и др.]. — Curran Associates, Inc., 2022. — С. 19523—19536. — arXiv: [2206.14486](https://arxiv.org/abs/2206.14486) [cs.LG]. — NeurIPS 2022 Outstanding Paper Award.
8. Kish L. Survey Sampling. — New York : John Wiley & Sons, 1965.
9. Geyer C. J. Practical Markov Chain Monte Carlo // Statistical Science. — 1992. — Т. 7, № 4. — С. 473—483. — DOI: [10.1214/ss/1177011137](https://doi.org/10.1214/ss/1177011137).

10. Curriculum Learning / Y. Bengio [и др.] // Proceedings of the 26th Annual International Conference on Machine Learning (ICML). — 2009. — С. 41—48. — DOI: [10.1145/1553374.1553380](https://doi.org/10.1145/1553374.1553380).
11. *Kumar M. P., Packer B., Koller D.* Self-Paced Learning for Latent Variable Models // Advances in Neural Information Processing Systems 23 (NIPS). — 2010. — С. 1189—1197.
12. Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics / S. Swayamdipta [и др.] // Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). — Association for Computational Linguistics, 2020. — С. 9275—9293. — DOI: [10.18653/v1/2020.emnlp-main.746](https://doi.org/10.18653/v1/2020.emnlp-main.746).
13. *Rahane A. A., Subramanian A.* Measures of Complexity for Large Scale Image Datasets // 2020 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC). — IEEE, 2020. — С. 282—287. — DOI: [10.1109/ICAIIIC48513.2020.9065274](https://doi.org/10.1109/ICAIIIC48513.2020.9065274). — arXiv: [2008.04431 \[cs.CV\]](https://arxiv.org/abs/2008.04431).
14. *Ho T. K., Basu M.* Complexity Measures of Supervised Classification Problems // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2002. — Март. — Т. 24, № 3. — С. 289—300. — DOI: [10.1109/34.990132](https://doi.org/10.1109/34.990132).
15. How Complex Is Your Classification Problem? A Survey on Measuring Classification Complexity / A. C. Lorena [и др.] // ACM Computing Surveys. — 2019. — Т. 52, № 5. — DOI: [10.1145/3347711](https://doi.org/10.1145/3347711).
16. *Smith M. R., Martinez T., Giraud-Carrier C.* An Instance Level Analysis of Data Complexity // Machine Learning. — 2014. — Т. 95, № 2. — С. 225—256. — DOI: [10.1007/s10994-013-5422-z](https://doi.org/10.1007/s10994-013-5422-z).
17. *Vapnik V. N., Chervonenkis A. Y.* On the Uniform Convergence of Relative Frequencies of Events to Their Probabilities // Theory of Probability & Its Applications. — 1971. — Т. 16, № 2. — С. 264—280. — DOI: [10.1137/1116025](https://doi.org/10.1137/1116025).

18. *Koltchinskii V., Panchenko D.* Rademacher Processes and Bounding the Risk of Function Learning // High Dimensional Probability II / под ред. E. Giné, D. M. Mason, J. A. Wellner. — Boston, MA : Birkhäuser, 2000. — С. 443—457.
19. LIDL: Local Intrinsic Dimension Estimation Using Approximate Likelihood / P. Tempczyk [и др.] // Proceedings of the 39th International Conference on Machine Learning (ICML 2022). Т. 162. — 2022. — С. 21205—21231. — (Proceedings of Machine Learning Research). — arXiv: [2206 . 14882 \[cs.LG\]](#).
20. A Geometric View of Data Complexity: Efficient Local Intrinsic Dimension Estimation with Diffusion Models / H. Kamkari [и др.] // Advances in Neural Information Processing Systems 37 (NeurIPS 2024). — 2024. — arXiv: [2406.03537 \[cs.LG\]](#).
21. *Cover T. M., Thomas J. A.* Elements of Information Theory. — 2nd. — Hoboken, NJ : Wiley-Interscience, 2006.
22. *Friedman D., Dieng A. B.* The Vendi Score: A Diversity Evaluation Metric for Machine Learning // Transactions on Machine Learning Research. — 2023. — ISSN 2835-8856. — arXiv: [2210 . 02410 \[cs.LG\]](#). — URL: <https://openreview.net/forum?id=g970HbQyk1> ; Published 07/2023, OpenReview id g970HbQyk1.
23. *Pasarkar A. P., Dieng A. B.* Cousins of the Vendi Score: A Family of Similarity-Based Diversity Metrics for Science and Machine Learning // Proceedings of the 27th International Conference on Artificial Intelligence and Statistics (AISTATS). Т. 238. — PMLR, 2024. — С. 3808—3816. — (Proceedings of Machine Learning Research). — arXiv: [2310 . 12952 \[cs.LG\]](#). — URL: <https://proceedings.mlr.press/v238/pasarkar24a.html>.
24. *Kulesza A., Taskar B.* Determinantal Point Processes for Machine Learning // Foundations and Trends in Machine Learning. — 2012. — Т. 5, № 2/3. — С. 123—286. — DOI: [10.1561/22000000044](#). — arXiv: [1207.6083 \[stat.ML\]](#).

25. *Roy O., Vetterli M.* The Effective Rank: A Measure of Effective Dimensionality // Proceedings of the 15th European Signal Processing Conference (EUSIPCO). — Poznan, Poland : EURASIP, 2007. — C. 606—610.
26. Numerical Methods of Sufficient Sample Size Estimation for Generalised Linear Models / T. T. Gadaev [и др.] // Lobachevskii Journal of Mathematics. — 2022. — T. 43, № 9.
27. *Grabovoy A. V., Strijov V. V.* Probabilistic Interpretation of the Distillation Problem // Automation and Remote Control. — 2022. — T. 83, № 1.
28. *Grabovoy A. V.* Methods for estimating the complexity of deep learning models and data : Doctoral dissertation / Grabovoy Andrey V. — Moscow : Moscow Institute of Physics, Technology, 2025.
29. *Azeglio S., Di Bernardo A.* What's Inside Your Diffusion Model? A Score-Based Riemannian Metric to Explore the Data Manifold // arXiv preprint arXiv:2505.11128. — 2025. — arXiv: [2505.11128](https://arxiv.org/abs/2505.11128) [cs.LG].
30. *Song J., Meng C., Ermon S.* Denoising Diffusion Implicit Models // 9th International Conference on Learning Representations (ICLR). — 2021. — arXiv: [2010.02502](https://arxiv.org/abs/2010.02502) [cs.LG].
31. Diffusion Autoencoders: Toward a Meaningful and Decodable Representation / K. Preechakul [и др.] // IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2022. — C. 10619—10629. — DOI: [10.1109/CVPR52688.2022.01036](https://doi.org/10.1109/CVPR52688.2022.01036).
32. *Kwon M., Jeong J., Uh Y.* Diffusion Models Already Have a Semantic Latent Space // 11th International Conference on Learning Representations (ICLR). — 2023. — arXiv: [2210.10960](https://arxiv.org/abs/2210.10960) [cs.CV].
33. Perception Prioritized Training of Diffusion Models / J. Choi [и др.] // IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2022. — C. 11472—11481. — DOI: [10.1109/CVPR52688.2022.01118](https://doi.org/10.1109/CVPR52688.2022.01118).
34. *Krause A., Singh A., Guestrin C.* Near-Optimal Sensor Placements in Gaussian Processes: Theory, Efficient Algorithms and Empirical Studies // Journal of Machine Learning Research. — 2008. — T. 9. — C. 235—284. — URL: <https://jmlr.org/papers/v9/krause08a.html>.

35. Gaussian Process Optimization in the Bandit Setting: No Regret and Experimental Design / N. Srinivas [и др.] // Proceedings of the 27th International Conference on Machine Learning (ICML). — Omnipress, 2010. — С. 1015—1022. — arXiv: [0912.3995](https://arxiv.org/abs/0912.3995) [cs.LG].
36. *Narayanan H.* Sample Complexity in Manifold Learning // Manifold Learning Theory and Applications / под ред. Y. Ma, Y. Fu. — Boca Raton, FL : CRC Press, 2011. — С. 73—86.
37. *Ma Y., Fu Y.* Manifold Learning Theory and Applications. — CRC Press, 12.2011.
38. *Fefferman C., Mitter S., Narayanan H.* Testing the Manifold Hypothesis // Journal of the American Mathematical Society. — 2016. — Т. 29, № 4. — С. 983—1049. — DOI: [10.1090/jams/852](https://doi.org/10.1090/jams/852).
39. The Intrinsic Dimension of Images and Its Impact on Learning / P. Pope [и др.] // 9th International Conference on Learning Representations (ICLR). — 2021. — arXiv: [2104.08894](https://arxiv.org/abs/2104.08894) [cs.LG].
40. *Berg C., Christensen J. P. R., Ressel P.* Harmonic Analysis on Semigroups: Theory of Positive Definite and Related Functions. Т. 100. — New York : Springer, 1984. — (Graduate Texts in Mathematics).
41. *Alpay D., Mayats-Alpay L.* Similarity Metrics, Metrics, and Conditionally Negative Definite Functions // arXiv preprint arXiv:2307.10446. — 2023. — math.FA.
42. *Bretagnolle J., Dacunha-Castelle D., Krivine J.-L.* Lois stables et espaces L^p // Annales de l'Institut Henri Poincaré, Section B. — 1966. — Т. 2, № 3. — С. 231—259.
43. *Koldobsky A.* Schoenberg's problem on positive definite functions // Algebra i Analiz (St. Petersburg Mathematical Journal). — 1991. — Т. 3, № 3. — С. 78—85.
44. *Robertson G.* Negative type and bi-Lipschitz embeddings into Hilbert space // arXiv preprint arXiv:2309.16070. — 2023.
45. Score-Based Generative Modeling through Stochastic Differential Equations / Y. Song [и др.] // International Conference on Learning Representations (ICLR). — 2021.

46. *Bishop C. M., Bishop H.* Deep Learning: Foundations and Concepts. — Cham : Springer, 2024.
47. *Teschl G.* Ordinary Differential Equations and Dynamical Systems. T. 140. — Providence, RI : American Mathematical Society, 2012. — (Graduate Studies in Mathematics).
48. *Chen S., Ma B., Zhang K.* On the Similarity Metric and the Distance Metric // Theoretical Computer Science. — 2009. — T. 410, № 24/25. — C. 2365—2376.
49. *Horn R. A., Johnson C. R.* Matrix Analysis. — 2nd. — Cambridge University Press, 2013.
50. *Aronszajn N.* Theory of reproducing kernels // Transactions of the American Mathematical Society. — 1950. — T. 68, № 3. — C. 337—404.