

Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский физико-технический институт
(национальный исследовательский университет)»
Физтех-школа прикладной математики и информатики
Кафедра интеллектуальных систем

Черноусов Данила Владиславович

**ГЕОМЕТРИЧЕСКИЙ ПОДХОД К ОЦЕНКЕ
СЛОЖНОСТИ ДАННЫХ НА ОСНОВЕ ГЕНЕРАТИВНЫХ
ДИФФУЗИОННЫХ МОДЕЛЕЙ**

03.03.01 — Прикладные математика и физика

Выпускная квалификационная работа бакалавра

Научный руководитель:
Грабовой Андрей Валериевич,
кандидат физико-математических наук

Москва — 2026

Содержание

1	Введение	4
1.1	Цели и задачи	5
1.2	Методы	6
1.3	Апробация	6
1.4	Структура работы	6
2	Постановка задачи	6
3	Предлагаемое решение	8
3.1	Мера сложности и положительно полуопределённые ядра . . .	9
3.2	Критерий положительной определённости ядра	11
3.3	Условно отрицательно определённые расстояния в L^p	12
3.4	Реализация: траекторное вложение	13
4	Вычислительные эксперименты	17
4.1	Скорость роста меры на траекторном вложении	17
4.2	Изображения MNIST	19
5	Заключение	20
A	Используемые результаты	23
B	Доказательства	23

Аннотация

Качество модели машинного обучения определяется не только объёмом обучающей выборки, но и тем, сколько различной информации она несёт: две выборки одного размера могут заметно различаться по разнообразию, а с ним и по сложности задачи обучения. Существующие меры сложности данных описывают лишь локальную размерность или не улавливают семантическую геометрию порождающего распределения. В работе изучаются меры сложности выборки, не требующие разметки, а само понятие сложности формализуется через три требования из теории меры: инвариантность к перестановкам, субаддитивность и монотонность. Доказано достаточное условие корректности меры и установлены точные двусторонние границы на прирост сложности при добавлении одного объекта. Чтобы вычислить меру на реальных данных, используется предобученная диффузионная модель. Объект представляется всей своей траекторией зашумления и тем самым сравнивается с другими сразу на всех масштабах, а порождаемое расстояние является метрикой и отражает семантическую близость объектов. Эксперименты на смесях гауссиан и на изображениях MNIST подтверждают, что мера отражает семантическое разнообразие, а не объём выборки.

1 Введение

Качество модели машинного обучения определяется не только объёмом обучающей выборки: две выборки одинакового размера могут заметно различаться по разнообразию и информативности, а с ними и по тому, насколько сложную модель они позволяют обучить и насколько хорошо она обобщает [1; 2]. Это видно уже на простых примерах. Набор из тысяч почти одинаковых кадров одного видеоролика или из множества сдвигов и небольших поворотов одного изображения формально велик, но все его объекты получены из одного и почти не добавляют разнообразия [3]. Куда тоньше избыточность семантическая: выборка из одних только фотографий кошек несёт меньше информации, чем выборка той же длины из кошек и собак. При этом изображения кошек не получают друг из друга простым геометрическим преобразованием в пиксельном пространстве, поэтому поверхностные методы такую избыточность не улавливают, и для её обнаружения объекты приходится представлять в признаковом пространстве и измерять близость уже там [4]. Даже стандартные наборы изображений содержат значимую долю семантически избыточных примеров, выявляемых лишь по таким представлениям [5]. По той же причине число токенов, привычная ось в законах масштабирования качества [6], слабо отражает информативность текстового корпуса. В реальности токены сильно зависимы и избыточны [7], и удаление дубликатов или отбраковка лишних примеров способны не ухудшить обучение, а улучшить его [8; 9]. В подобных случаях информативен не объём, а эффективный размер выборки. Это понятие давно формализовано в статистике: зависимые или избыточные наблюдения несут меньше информации, чем столько же независимых, и реальное число объектов может многократно превышать эффективный размер выборки [10]. Поэтому возникает потребность в мере сложности выборки, которая численно отражала бы это разнообразие и была бы согласована с геометрией порождающего распределения. Такая мера полезна для прогнозирования качества модели по характеристикам данных, для адаптивного обучения, то есть отбора обучающих подвыборок с учётом их сложности [11; 12], и для сравнения наборов данных одного объёма, но разного содержания [13; 14].

Существующие меры сложности данных можно разделить на два рода. Первый тип мер сложности оценивает сложность задачи классификации по

размеченной выборке. Меры перекрытия признаков и делимости классов Хо и Басу [15], систематизированные в обзоре [16], оценки трудности отдельных объектов [17], а также классические меры ёмкости класса гипотез, такие как размерность Вапника–Червоненкиса [18] и сложность Радемахера [19]. Все они отвечают на вопрос, насколько трудно выучить разметку, и не определены без меток.

Меры второго рода работают без меток. Часть из них оценивает локальную размерность многообразия данных [20; 21], то есть характеристику отдельной точки, а не всей выборки. Другое направление, спектральные меры разнообразия, сводит выборку к спектру матрицы попарной похожести. Первой такой конструкцией стал эффективный ранг [22] — вещественнозначное обобщение ранга матрицы. Vendi Score [23] представляет собой экспоненту энтропии её собственных значений и измеряет разнообразие выборки. Эта мера наиболее близка к предлагаемой мере сложности. Vendi Score не требует ни меток, ни эталонного распределения, ни заранее заданных категорий и применим к любому источнику данных, для которого определена похожест объектов.

1.1 Цели и задачи

Цель работы состоит в том, чтобы построить и обосновать меру сложности выборки, учитывающую семантическую геометрию данных. Для достижения цели решаются следующие задачи:

1. Формализовать понятие выборки и описать требования к мере сложности.
2. Построить меру по положительно полуопределённому ядру, доказать её корректность и установить её свойства.
3. Предложить реализацию меры через траекторное вложение диффузионной модели и обосновать корректность этой реализации.
4. Экспериментально проверить, что мера согласуется с семантическим разнообразием данных.

1.2 Методы

Работа опирается на теорию положительно и условно отрицательно определённых ядер и воспроизводящих ядерных гильбертовых пространств, спектральные характеристики ядерных матриц, теорию ОДУ вероятностного потока диффузионных моделей с численным интегрированием траекторий, а также на вычислительный эксперимент на синтетических данных и изображениях.

1.3 Апробация

Основные результаты работы были представлены на 68-й Всероссийской научной конференции МФТИ в секции проблем интеллектуального анализа данных, распознавания и прогнозирования, апрель 2026 г.

1.4 Структура работы

В разделе 2 формализуется понятие выборки и вводится мера сложности. В разделе 3 строится мера по положительно полуопределённому ядру, доказываются теоремы о её корректности и свойствах и приводится реализация через траекторное вложение диффузионной модели. Раздел 4 содержит вычислительные эксперименты, а раздел 5 посвящён заключению.

2 Постановка задачи

Определение 2.1. *Распределением данных* называется вероятностная мера p на $\mathbb{R}^d$, абсолютно непрерывная относительно меры Лебега, с плотностью $p(\mathbf{x})$.

Определение 2.2. *Генеральной совокупностью* X называется множество $\text{supp } p \subseteq \mathbb{R}^d$.

На практике носитель X редко заполняет всё пространство $\mathbb{R}^d$. Согласно гипотезе многообразия, высокоразмерные данные сосредоточены вблизи низкоразмерного многообразия, поскольку порождающий их процесс обладает немногими существенными степенями свободы [24; 25]. Эта гипотеза имеет теоретическое обоснование [26] и эмпирические подтверждения, в которых

внутренняя размерность типичных наборов изображений оказывается на порядки меньше размерности пикселей [20; 27]. Простой пример многообразия данных даёт орбита одного изображения под действием группы преобразований. Вращения плоскости $SO(2)$ порождают одномерное многообразие, а сдвиги и малые повороты дают многообразие, размерность которого равна числу параметров преобразования и не зависит от размерности d объемлющего пространства. Внутренняя размерность данных обычно много меньше размерности наблюдений d . Поэтому содержательную сложность выборки естественно измерять не размерностью объемлющего пространства и не числом объектов, а числом реально занятых независимых направлений.

Определение 2.3. *Выборкой* объёма N называется набор объектов

$$X = (\mathbf{x}_1, \dots, \mathbf{x}_N) \in \mathcal{X}^N,$$

возможно с повторами.

Определение 2.4. *Мерой сложности выборки* называется отображение

$$\mu_D : \bigcup_{N \geq 1} \mathcal{X}^N \rightarrow \mathbb{R}_+,$$

определённое на выборках произвольного объёма и удовлетворяющее трём условиям [28]:

(C1) *инвариантность к перестановкам*: для любой перестановки $\pi \in S_N$

$$\mu_D(\mathbf{x}_{\pi(1)}, \dots, \mathbf{x}_{\pi(N)}) = \mu_D(\mathbf{x}_1, \dots, \mathbf{x}_N);$$

(C2) *субаддитивность*: для любых выборок X, Y

$$\mu_D(X \cup Y) \leq \mu_D(X) + \mu_D(Y);$$

(C3) *монотонность*: для любой выборки X и объекта $\mathbf{x}$

$$\mu_D(X) \leq \mu_D(X \cup \{\mathbf{x}\}).$$

Условие (C1) означает, что μ_D зависит лишь от состава выборки, но не

от порядка её объектов. Сложность есть свойство самих данных, а не способа их перечисления. Условие (C2) выражает субаддитивность [28]. У двух выборок часть содержания может совпадать, поэтому их объединение не сложнее суммы сложностей. Условие (C3) требует, чтобы добавление данных не уменьшало сложность. Новое наблюдение способно открыть дополнительное направление, но не отменить уже занятые. Эти три условия описывают поведение меры при перестановке, объединении и расширении выборки, трёх элементарных операциях над её составом. Для конечных множеств в теории меры монотонность следует из субаддитивности. Для выборок с повторами это уже не так, поэтому условие (C3) приходится требовать отдельно. Соответствующий пример приведён ниже.

Утверждение 2.5. *Условие (C3) не следует из (C1)–(C2).*

Доказательство.

Рассмотрим меру $\mu_D(X) = f(|X|)$, зависящую только от объёма выборки, где $f(0) = 0$, $f(1) = 2$ и $f(n) = 1$ при $n \geq 2$. Она удовлетворяет (C1), так как зависит лишь от $|X|$, и (C2), так как $f(m+n) \leq f(m) + f(n)$ для всех $m, n \geq 0$. Однако $f(2) = 1 < 2 = f(1)$, таким образом добавление второго объекта уменьшает сложность. Условие (C3) нарушено. $\square$

3 Предлагаемое решение

В этом разделе мы показываем, что любое положительно полуопределённое ядро с единичной диагональю порождает корректную меру сложности (теорема 3.2). Затем мы пользуемся классическим критерием Шёнберга, который выражает положительную полуопределённость ядра через порождающую его функцию ψ (теорема 3.5). В разделе 3.3 это расстояние строится явно как L^p -метрика, ядро которой положительно полуопределено (теорема 3.6). Наконец в разделе 3.4 расстояние реализуется через траектории диффузионного процесса как частный случай этой схемы.

3.1 Мера сложности и положительно полуопределённые ядра

Под *ядром* на $\mathcal{X}$ мы, следуя теории положительно и отрицательно определённых функций [29, гл. 3], понимаем произвольную симметричную функцию $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$. Каждой выборке $X = (\mathbf{x}_1, \dots, \mathbf{x}_N)$ ядро сопоставляет симметричную *матрицу ядра* $K(X) = (k(\mathbf{x}_i, \mathbf{x}_j))_{i,j=1}^N$ своих значений на X .

Определение 3.1. Ядро k называется *положительно полуопределённым* (ППО) [29, гл. 3], если для любого N , любых $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathcal{X}$ и любого $\mathbf{c} \in \mathbb{R}^N$

$$\sum_{i,j=1}^N c_i c_j k(\mathbf{x}_i, \mathbf{x}_j) \geq 0,$$

то есть всякая матрица ядра $K(X)$ положительно полуопределена ($K \succeq 0$). Если $k(\mathbf{x}, \mathbf{x}) = 1$ для всех $\mathbf{x}$, то $K_{ii} = 1$ и $|K_{ij}| \leq 1$.

По ППО-ядру k с $k(\mathbf{x}, \mathbf{x}) = 1$ определяем меру сложности

$$\mu_D(X) = \log \det (I + K(X)). \quad (1)$$

Собственные числа $\nu_1, \dots, \nu_N$ матрицы $K \succeq 0$ неотрицательны, собственные числа матрицы $I + K$ равны $1 + \nu_k$, а её определитель равен их произведению, поэтому

$$\mu_D(X) = \log \prod_{k=1}^N (1 + \nu_k) = \sum_{k=1}^N \log(1 + \nu_k).$$

Функционал $\log \det(I + K)$ совпадает с информационным выигрышем гауссовского процесса [30; 31]. Он также является дифференциальной энтропией гауссова распределения с матрицей ковариации K [32].

Спектральное представление $\mu_D = \sum_k \log(1 + \nu_k)$ проясняет смысл меры. Каждое собственное число ν_k матрицы ядра отвечает одному независимому направлению в порождённом ядром признаковом пространстве. Вклад этого направления в сложность равен $\log(1 + \nu_k)$ и растёт с его выраженностью ν_k . Рост идёт с насыщением, и сильно занятое направление добавляет к сложности немногим больше, чем умеренно занятое. Поэтому мера вознаграждает появление новых направлений, а не повторение уже занятых. Тот же смысл

несёт информационная интерпретация. Величина μ_D показывает, сколько в среднем требуется информации, чтобы описать выборку, наблюдаемую через гауссовский процесс с ковариацией K .

Для выборок X, Y через $X \cup Y$ обозначаем их конкатенацию, матрица ядра при этом блочная

$$K(X \cup Y) = \begin{pmatrix} K(X) & B \\ B^\top & K(Y) \end{pmatrix}, \quad B = (k(\mathbf{x}_i, \mathbf{y}_j)).$$

Теорема 3.2. Пусть k — ППО-ядро на X с $k(\mathbf{x}, \mathbf{x}) = 1$ для всех $\mathbf{x}$. Тогда μ_D из (1) — мера сложности выборки в смысле определения 2.4, причём для любого $N \geq 1$, любой выборки $X \in \mathcal{X}^N$ и любого объекта $\mathbf{x} \in X$ верно неравенство:

$$\log \frac{N+2}{N+1} \leq \mu_D(X \cup (\mathbf{x})) - \mu_D(X) \leq \log 2;$$

в частности, прирост всегда строго положителен.

Доказательство.

Доказательство приведено в приложении В. □

Для одиночного объекта $K((\mathbf{x})) = 1$ и $\mu_D((\mathbf{x})) = \log 2$: нормировка $k(\mathbf{x}, \mathbf{x}) = 1$ фиксирует сложность отдельно взятого объекта. Верхняя граница означает, что новый объект не может добавить к сложности выборки больше собственной сложности $\log 2$. Максимальный прирост $\log 2$ достигается в точности тогда, когда $k(\mathbf{x}, \mathbf{x}_i) = 0$ для всех i . Такой объект не объясняется уже имеющимися наблюдениями и потому несёт максимум новой информации.

Нижняя граница показывает, что даже точная копия уже имеющегося объекта строго увеличивает сложность. Но повторы быстро обесцениваются. Граница неулучшаема. Худший случай — выборка из N копий одного объекта, для которой K — матрица из единиц со спектром $(N+1, 1, \dots, 1)$, так что $\mu_D = \log(N+1)$, и каждая следующая копия добавляет ровно $\log \frac{N+2}{N+1}$.

У этого крайнего случая есть теоретико-информационный смысл. Выборка из N копий одного объекта несёт информацию только о числе повторов, а её содержание описывается одним объектом. Величина $\log(N+1)$ по порядку совпадает с количеством информации, необходимым, чтобы закодировать целое число от 0 до N , то есть записать размер выборки. На полностью вырож-

денной выборке мера вырождается в информацию об одном лишь её объёме.

Следствие 3.3. Для $A \subseteq B$ и объекта $\mathbf{x}$ выполнено

$$\mu_D(A \cup (\mathbf{x})) - \mu_D(A) \geq \mu_D(B \cup (\mathbf{x})) - \mu_D(B).$$

Доказательство.

Доказательство приведено в приложении В. □

Это свойство означает, что скорость роста сложности убывает: чем больше выборка, тем меньше прирост от добавления нового объекта. У этого есть наглядная вероятностная интерпретация. Если рассматривать k как ковариацию гауссовского процесса, то прирост сложности связан с апостериорной дисперсией предсказания в новой точке по уже имеющейся выборке. Добавление наблюдений эту дисперсию не увеличивает, поэтому ценность каждого следующего объекта тем меньше, чем больше похожих на него объектов уже есть.

3.2 Критерий положительной определённости ядра

Теорема 3.2 требует ППО-ядра. Опишем, когда оно таково. Ядра вида $k = e^{-\lambda\psi}$ строятся по симметричной функции ψ , и критерий формулируется в терминах условной отрицательной определённости.

Определение 3.4. Ядро ψ называется *условно отрицательно определённым* (УОО) [29, гл. 3], если для любого N , любых $\mathbf{x}_1, \dots, \mathbf{x}_N \in \mathcal{X}$ и любого $\mathbf{c} \in \mathbb{R}^N$ с $\sum_i c_i = 0$

$$\sum_{i,j} c_i c_j \psi(\mathbf{x}_i, \mathbf{x}_j) \leq 0.$$

Систематическое изложение приводимого далее критерия дано в [29, гл. 3].

Теорема 3.5 (Шёнберг, 1938). Для симметричного ψ с $\psi(\mathbf{x}, \mathbf{x}) = 0$ эквивалентны:

- (i) ψ условно отрицательно определено.
- (ii) Ядро $e^{-\lambda\psi}$ положительно полуопределено при всех $\lambda > 0$.

(iii) Существуют гильбертово пространство $\mathcal{H}$ и отображение $\Phi : X \rightarrow \mathcal{H}$ с $\psi(\mathbf{x}, \mathbf{y}) = \|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|_{\mathcal{H}}^2$.

Более того, если ψ УОО, то ψ^α УОО при всех $\alpha \in (0, 1]$, и эта граница точна.

Теоремы 3.2 и 3.5 вместе дают целый класс мер сложности. Каждая УОО-функция ψ с нулевой диагональю и каждая пара параметров $\lambda > 0$, $\alpha \in (0, 1]$ порождают корректную меру $\mu_D(X) = \log \det (I + (e^{-\lambda \psi^\alpha(\mathbf{x}_i, \mathbf{x}_j)}))$. Степень свободы конструкции состоит в выборе функции ψ , которая должна задавать семантическую отдалённость объектов. Для семантически близких объектов $\psi \approx 0$ и ядро $e^{-\lambda \psi} \approx 1$, так что такая пара почти не увеличивает сложность по сравнению с одним объектом. Для семантически далёких объектов ψ велико, ядро близко к нулю, и вклады объектов складываются как независимые по $\log 2$ на объект (теорема 3.2).

Пункт (iii) теоремы 3.5 даёт геометрическую интерпретацию допустимых функций. Функция ψ УОО в точности тогда, когда $\psi(\mathbf{x}, \mathbf{y}) = \|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|_{\mathcal{H}}^2$ для некоторого вложения Φ в гильбертово пространство. Иными словами, выбрать ψ — то же самое, что выбрать представление объектов точками гильбертова пространства, в котором семантическая отдалённость измеряется метрикой этого пространства. Допустимы все способы спрямить семантику в гильбертову геометрию и только они. А ядро $k = e^{-\lambda \|\Phi(\mathbf{x}) - \Phi(\mathbf{y})\|^2}$ является при этом гауссовым ядром в пространстве представлений. Параметр λ задаёт масштаб, на котором различия представлений считаются существенными, а μ_D считает эффективное число различимых на этом масштабе представлений.

3.3 Условно отрицательно определённые расстояния в L^p

В этом разделе обобщается теорема [33] на векторозначные функции, которые будут использоваться нами далее.

Теорема 3.6. Пусть (T, μ) — пространство с конечной мерой, $p \in (0, 2]$, $\beta \in (0, 2]$, $\lambda > 0$, и отображение $x \mapsto \varphi_x \in L^p(T, \mu; \mathbb{R}^d)$ инъективно. Тогда

$$D(x, y) = \left(\int_T \|\varphi_x(t) - \varphi_y(t)\|^p d\mu(t) \right)^{1/2}$$

является метрикой, а ядро $k(x, y) = e^{-\lambda D(x, y)^\beta}$ положительно полуопределено.

Доказательство.

Доказательство приведено в приложении В. □

При $p < 1$ пространство $L^p(T, \mu; \mathbb{R}^d)$ не является гильбертовым и даже нормированным: для $(\int_T \|\cdot\|^p d\mu)^{1/p}$ нарушается неравенство треугольника. Поэтому мы рассматриваем его просто как множество, на котором заданы отображения φ_x . При $\beta = 2$ ядро $e^{-\lambda D^2}$ гауссово, а при $\beta = 1$ ядро $e^{-\lambda D}$ лапласово.

3.4 Реализация: траекторное вложение




Рис. 1: Схема предлагаемого метода. Каждому объекту сопоставляется траектория ОДУ вероятностного потока диффузионной модели, по попарным расстояниям между траекториями строится положительно полуопределённое ядро, а сложность выборки определяется как $\mu_D(X) = \log \det(I + K)$.

Чтобы построить ядро на реальных данных, каждому объекту нужно сопоставить представление, в котором близость отражает семантическое сходство. Такое представление доставляют генеративные диффузионные модели. В их основе лежат два согласованных процесса. Прямой процесс постепенно зашумляет данные, добавляя гауссов шум растущей дисперсии, пока распределение не превратится в практически чистый шум. Обратный процесс восстанавливает данные из шума, последовательно его убирая. Оба процесса определяются скор-функцией зашумлённого распределения. Зная скор-функцию на всех уровнях шума, можно порождать новые объекты и можно детерминированно проводить уже имеющийся объект через все масштабы шума. Эту детерминированную траекторию мы и берём в качестве представления объекта. В оставшейся части раздела формализуются зашумление, скор-функция и порождаемое ими ОДУ вероятностного потока.

Определение 3.7. Процессом зашумления плотности p на $\mathbb{R}^d$ называется семейство распределений

$$p_t(\mathbf{x}) = (p * \mathcal{N}(\mathbf{0}, \sigma^2(t)\mathbf{I}))(\mathbf{x}) = \int_{\mathbb{R}^d} p(\mathbf{y}) \frac{1}{(2\pi\sigma^2(t))^{d/2}} \exp\left(-\frac{\|\mathbf{x} - \mathbf{y}\|^2}{2\sigma^2(t)}\right) d\mathbf{y}, \quad (2)$$

где $\sigma : [0, 1] \rightarrow \mathbb{R}_+$ монотонно возрастает и $\sigma(0) = 0$.

Свёртка с гауссовым ядром размывает распределение: при $t = 0$ получаются сами данные $p_0 = p$, а с ростом дисперсии $\sigma^2(t)$ распределение p_t переходит к чистому шуму [34; 35].

Определение 3.8. Скор-функцией зашумлённого распределения p_t называется логарифмический градиент его плотности

$$\mathbf{s}(\mathbf{x}, t) = \nabla_{\mathbf{x}} \ln p_t(\mathbf{x}).$$

Скор-функция указывает в сторону роста плотности, то есть по нормали к многообразию данных, и её величина растёт с удалением от него. Скор-поле кодирует геометрию многообразия данных [21; 36]. Истинная скор-функция неизвестна и на практике её оценивает обученная диффузионная модель $\mathbf{s}_\theta(\mathbf{x}, t) \approx \nabla_{\mathbf{x}} \ln p_t(\mathbf{x})$ с параметрами θ .

Предположение 3.9. Скор-поле $\mathbf{s}(\cdot, t)$ липшицево по первому аргументу с константой L , равномерной по $t \in [0, 1]$, и непрерывно по t , функция σ непрерывно дифференцируема.

Детерминированным аналогом зашумления служит ОДУ вероятностного потока: оно сохраняет маргинальные распределения процесса на каждом уровне шума.

Утверждение 3.10. Пусть $\mathbf{z}_{\mathbf{x}}(t)$ — решение ОДУ вероятностного потока

$$\frac{d\mathbf{z}}{dt} = -\sigma(t)\dot{\sigma}(t)\mathbf{s}(\mathbf{z}(t), t), \quad \mathbf{z}_{\mathbf{x}}(0) = \mathbf{x}. \quad (3)$$

Если $\mathbf{x} \sim p$, то при каждом $t \in [0, 1]$ случайная величина $\mathbf{z}_{\mathbf{x}}(t)$ имеет ту же плотность p_t , что и процесс зашумления из определения 3.7 [34].

Решение $\mathbf{z}_x(t)$ ведёт объект $\mathbf{x}$ от данных к чистому шуму, а вложение $\Phi(\mathbf{x}) = \mathbf{z}_x(\cdot)$ сопоставляет ему эту траекторию как кривую на отрезке. Траектория проходит все уровни шума и на разных масштабах кодирует разную близость объектов: при малом шуме ($t \rightarrow 0$) — форму и внешний вид, при большом ($t \rightarrow 1$) — семантику и класс [37]. Сама детерминированная траектория несёт содержательную семантическую информацию: она переводит объект в латентный код с осмысленной интерполяцией [38; 39], а вдоль неё у предобученной модели уже существует семантическое латентное пространство [40].

Тем самым реализуется недостающая функция ψ из общей конструкции: несходство объектов определяем как квадрат L^2 -нормы между траекториями по мере μ_w на отрезке $[0, 1]$:

$$D(\mathbf{x}_i, \mathbf{x}_j)^2 = \int_0^1 \|\mathbf{z}_{\mathbf{x}_i}(t) - \mathbf{z}_{\mathbf{x}_j}(t)\|^2 d\mu_w(t), \quad (4)$$

то есть квадрат нормы в $L^2([0, 1], \mu_w; \mathbb{R}^d)$.

Мера μ_w задаёт вклад каждого масштаба шума в расстояние, чем больше массы она помещает в окрестность момента t , тем сильнее на D влияют различия объектов на уровне шума $\sigma(t)$. Поскольку время пробегает отрезок $[0, 1]$, в качестве μ_w естественно взять семейство бета-распределений на $[0, 1]$ с плотностью $\text{Beta}(t; a, b)$. Подбором параметров (a, b) массу можно сосредоточить у любого конца отрезка или в его середине, причём равномерная мера ($a = b = 1$) и сколь угодно острые приближения точечной меры δ_{t_0} входят как частные случаи; в последнем пределе расстояние (4) сводится к сравнению траекторий в один момент времени, $\|\mathbf{z}_{\mathbf{x}_i}(t_0) - \mathbf{z}_{\mathbf{x}_j}(t_0)\|^2$.

Расстояние (4) по своей сути представляет собой квадрат нормы в гильбертовом пространстве траекторий $\mathcal{H} = L^2([0, 1], \mu_w; \mathbb{R}^d)$; объект $\mathbf{x}$ вкладывается в него траекторией $\Phi(\mathbf{x}) = \mathbf{z}_x(\cdot)$. Следующее утверждение формально переносит УОО-свойство с пространства траекторий на объекты выборки.

Утверждение 3.11. *При предположении 3.9 функция $D^2 : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ из (4) симметрична, имеет нулевую диагональ и условно отрицательно определена на $\mathbb{R}^d$; то же верно для всех степеней D^β , $\beta \in (0, 2]$.*

Итоговая мера сложности выборки $X = (\mathbf{x}_1, \dots, \mathbf{x}_N)$:

$$\mu_D(X) = \log \det \left(I + \left(e^{-\lambda D^2(\mathbf{x}_i, \mathbf{x}_j)} \right)_{i,j=1}^N \right). \quad (5)$$

Утверждение 3.12. Пусть выполнено предположение 3.9, $\lambda > 0$, L — константа Липшица поля $\mathbf{s}$, $C = \sup_{t \in [0,1]} \sigma(t) \dot{\sigma}(t) < \infty$, и μ_D — мера (5). Тогда:

- (i) для любых $\mathbf{x}, \mathbf{x}' \in \mathbb{R}^d$ вложение Φ липшицево: $\|\Phi(\mathbf{x}) - \Phi(\mathbf{x}')\|_{\mathcal{H}} \leq e^{CL} \|\mathbf{x} - \mathbf{x}'\|$;
- (ii) для любой выборки X объёма N , индекса $k \in \{1, \dots, N\}$ и объекта $\mathbf{x}'_k \in \mathbb{R}^d$: если X' получена из X заменой $\mathbf{x}_k \mapsto \mathbf{x}'_k$, то

$$|\mu_D(X') - \mu_D(X)| \leq 2N\sqrt{2\lambda/e} e^{CL} \|\mathbf{x}_k - \mathbf{x}'_k\|;$$

- (iii) если поле $\widehat{\mathbf{s}}$ также удовлетворяет предположению 3.9 и $\sup_{\mathbf{z}, t} \|\mathbf{s}(\mathbf{z}, t) - \widehat{\mathbf{s}}(\mathbf{z}, t)\| \leq \varepsilon$, то для меры $\widehat{\mu}_D$, построенной по полю $\widehat{\mathbf{s}}$,

$$|\mu_D(X) - \widehat{\mu}_D(X)| \leq 2N^2\sqrt{2\lambda/e} C e^{CL} \varepsilon.$$

Доказательство.

Доказательство приведено в приложении В. □

Все три оценки означают устойчивость меры. Пункт (i) говорит, что близкие объекты порождают близкие траектории, поэтому вложение не раздувает расстояния. Пункт (ii): замена одного объекта выборки меняет μ_D ограниченно, то есть мера не чувствительна к малым возмущениям данных и к отдельным выбросам.

Так как истинная скор-функция неизвестна, в (5) вместо неё используется обученная диффузионная модель. Пункт (iii) гарантирует, что при равномерно малой ошибке аппроксимации скор-поля ε вычисленная мера отличается от идеальной не более чем на $O(N^2\varepsilon)$. Это означает, что предложенный метод оценки сложности корректно работает с реальной предобученной моделью, а не только с недоступной истинной скор-функцией.

4 Вычислительные эксперименты

4.1 Скорость роста меры на траекторном вложении

Эксперимент проверяет центральное свойство меры: μ_D должна считать эффективное число независимых семантических направлений в выборке, а не её объём N . Для этого при фиксированном N сравниваются выборки разной степени разнообразия, а затем прослеживается, как сложность растёт с N .

Постановка. Данные порождаются смесями гауссиан в $\mathbb{R}^2$, для которых скор-функция $s(\mathbf{x}, t) = \nabla_{\mathbf{x}} \log p_t(\mathbf{x})$ известна в замкнутой форме (аналитический скор, без обучения сети). Это исключает ошибку аппроксимации и позволяет изолированно проверять саму меру. Используется расписание шума VP. Для каждого объекта траектория $z_{\mathbf{x}}(t)$ получается интегрированием ОДУ вероятностного потока (3) на сетке из $L = 20$ моментов времени, равномерно покрывающих $[0,01; 0,99]$; объект представляется взвешенной траекторией, а расстояние между объектами вычисляется по (4) с гауссовым ядром (5). Ширина ядра λ калибруется один раз по независимой эталонной выборке из стандартной гауссианы ($\lambda \approx 0,345$) и далее фиксируется для всех выборок: иначе ширина подстраивалась бы под каждую выборку и нормализовала бы как раз те структурные различия, которые мы хотим измерить.

Рассматриваются три семейства выборок объёма N :

1. **Новый кластер на каждый объект.** N далеко разнесённых кластеров (расстояние между соседними центрами равно 20) на прямой, по одному объекту из каждого. Максимально разнообразная выборка: объекты не объясняют друг друга.
2. **Один кластер, $\sigma = 1$.** Все N объектов взяты из одной гауссианы умеренного разброса. Частично разнообразная выборка.
3. **Один кластер, $\sigma = 0,1$.** Все N объектов взяты из одной плотной гауссианы; объекты почти совпадают и являются приближёнными повторами.

Результаты. Измеренные значения μ_D для характерных N приведены в таблице 1; кривые показаны на рис. 2.




Рис. 2: Рост меры сложности $\mu_D(X)$ с объёмом выборки N для выборок разной структуры. Синяя кривая: каждый объект образует новый независимый кластер, сложность растёт по верхней границе $N \log 2$. Оранжевая и зелёная: все объекты из одного кластера с разбросом $\sigma = 1$ и $\sigma = 0,1$ соответственно; для плотного кластера рост выходит на нижнюю границу $\log(1 + N)$. Пунктиром показаны теоретические границы прироста.

Таблица 1: Сложность $\mu_D(X)$ для трёх режимов и теоретические границы.

N	новый кластер	$\sigma = 1$	$\sigma = 0,1$	$N \log 2$	$\log(1 + N)$
2	1,386	1,366	1,106	1,386	1,099
10	6,931	4,238	2,462	6,931	2,398
20	13,863	6,672	3,167	13,863	3,045
30	20,794	8,328	3,612	20,794	3,434

Выводы. Эксперимент прямо подтверждает двустороннюю границу прироста из теоремы 3.2: на максимально разнообразной выборке (новый кластер на объект) сложность идёт по верхней границе $N \log 2$, на почти повторяющейся ($\sigma = 0,1$) — выходит на нижнюю $\log(1 + N)$, а промежуточный режим $\sigma = 1$ устойчиво лежит между ними. Главное, при одном и том же объёме мера разделяет выборки по содержанию, а не по размеру: на порядок различаясь по сложности при равном N , она упорядочивает их по разнообразию, что и означает интерпретацию μ_D как эффективного числа независимых направлений.

4.2 Изображения MNIST

Этот эксперимент переносит проверку с контролируемой синтетики на реальные изображения, где распределение данных и скор-функция неизвестны и извлекаются из предобученной диффузионной модели.

Постановка. Используется диффузионная модель DDPM, предобученная на MNIST. Для каждого изображения $\mathbf{x} \in \mathbb{R}^{784}$ траектория $z_{\mathbf{x}}(t)$ ОДУ вероятностного потока (3) вычисляется численным интегрированием (пакетный метод Эйлера сразу по всем объектам выборки), причём скор берётся из сети по предсказанному шуму, $s(\mathbf{x}, t) = -\varepsilon_{\theta}(\mathbf{x}, t)/\sigma(t)$ согласно предположению 3.9. Объект представляется взвешенной траекторией с весами Beta(2, 2) на $L = 10$ моментах времени; ядро гауссово, а ширина λ снова калибруется по отложенной эталонной выборке. Сравниваются две выборки растущего объёма N :

- **одноклассовая** — только изображения цифры 0 (избыточная по смыслу выборка);
- **многоклассовая** — изображения, циклически перебирающие все классы 0, 1, ..., 9 (семантически разнообразная выборка).




Рис. 3: Рост меры сложности $\mu_D(X)$ с объёмом выборки N на изображениях MNIST. Выборка из изображений одного класса (цифра 0) имеет меньшую сложность, чем выборка из изображений разных классов, и разрыв между кривыми растёт с объёмом выборки.

Выводы. Поведение меры на реальных изображениях (рис. 3) повторяет картину синтетического эксперимента. Одноклассовая кривая вогнута и насыщается: каждое новое изображение той же цифры попадает в уже занятую семантическую область и добавляет всё меньше — проявление субмодулярности (следствие 3.3), аналог плотного кластера в синтетике. Многоклассовая кривая близка к прямой: каждый новый класс открывает новое семантическое направление и даёт примерно постоянный прирост. Разрыв между кривыми монотонно растёт с объёмом — это и есть надбавка за классовое разнообразие при равном размере выборки. В отличие от контролируемой синтетики, границы теоремы 3.2 не достигаются в точности (изображения внутри класса всё же различаются, а разные цифры не строго ортогональны), но это не мешает мере правильно упорядочить выборки.

Таким образом, траекторное вложение, построенное по предобученной диффузионной модели, переносит семантическую согласованность меры на реальные изображения: при равном объёме μ_D растёт быстрее для семантически разнообразных выборок и выходит на насыщение для избыточных.

5 Заключение

В работе предложена и обоснована мера сложности обучающей выборки, учитывающая семантическую геометрию данных, которая извлекается из предобученной диффузионной модели. Поставленные задачи решены.

Вклад автора.

1. Доказана теорема о достаточном условии корректности меры сложности выборки.
2. Доказана теорема о свойствах предложенной меры.
3. Предложен метод оценки сложности на основе траекторного вложения диффузионной модели.
4. Экспериментально подтверждена семантическая согласованность предложенной меры.

Формализовано понятие выборки, упорядоченной и допускающей повторы, и описаны требования к мере сложности: инвариантность к переста-

новкам, субаддитивность и монотонность. Показано, что для выборок с повторами монотонность не вытекает из субаддитивности и является самостоятельным требованием.

Доказана теорема о достаточном условии корректности. Для всякого положительно полуопределённого ядра с единичной диагональю мера $\mu_D(X) = \log \det(I + K)$ обладает всеми тремя свойствами, причём прирост сложности при добавлении объекта ограничен с обеих сторон точными границами $\log \frac{N+2}{N+1} \leq \Delta \leq \log 2$. Установлены дополнительные свойства меры, включая субмодулярность, а критерий Шёнберга описывает, какие ядра порождают корректную меру.

Предложена реализация меры через траекторное вложение диффузионной модели. Каждому объекту сопоставляется траектория ОДУ вероятностного потока, расстояние между траекториями D является метрикой при $p \in (0, 2]$, а порождаемое ядро $e^{-\lambda D^p}$ положительно полуопределено. Доказана липшицева устойчивость меры к возмущению скор-функции. Вычислительные эксперименты показали, что мера растёт вместе с семантическим разнообразием данных на синтетических наборах и на изображениях MNIST.

Практическая значимость состоит в том, что мера не требует разметки данных и снабжена доказанными гарантиями корректности. Она применима к оценке разнообразия наборов данных, к отбору обучающих подвыборок и к сравнению выборок одного объёма, но разного содержания.

Недостатки. Вычисление μ_D требует N интегрирований ОДУ вероятностного потока, $O(N^2)$ попарных расстояний между траекториями и логарифма определителя матрицы $N \times N$ за $O(N^3)$, и этот кубический по объёму выборки член ограничивает применение умеренными значениями N . Мера опирается на предобученную диффузионную модель и наследует её смещения и охват, поэтому осмыслена лишь в той области, на которой модель обучена, а вопрос об устойчивости μ_D к выбору модели остаётся открытым; полностью обойтись без представления данных при этом нельзя, так как семантическая близость не определена на сырых пикселях или токенах и требует представления объектов в признаковом пространстве (раздел 1). Наконец, как и другие меры разнообразия на основе похожести, μ_D измеряет внутреннее разнообразие выборки, а не её близость к эталонному распределению [23; 41]. Высокое значение можно получить и на бессмысленных данных, например на чистом

шуме, поэтому меру следует применять в паре с метрикой качества, а не отдельно.

План дальнейших исследований.

- *Применение к текстам.* Перенос траекторного вложения на текстовые данные с помощью текстовых (дискретных) диффузионных моделей и проверка семантической согласованности меры на корпусах.
- *Связь с обобщением.* Установление границ, связывающих μ_D с эффективностью обучения и обобщающей способностью моделей.
- *Прикладные сценарии.* Использование μ_D для отбора и семантической дедупликации обучающих данных, формирования адаптивных батчей, а также для оценки разнообразия и покрытия генеративных моделей в паре с метрикой качества.

А Используемые результаты

Здесь выписаны внешние результаты, на которые опираются доказательства из приложения В.

Теорема А.1 (Мур–Аронсajn, 1950). *Симметричное положительно полуопределённое ядро k на множестве X допускает представление [42]*

$$k(\mathbf{x}, \mathbf{y}) = \langle \phi(\mathbf{x}), \phi(\mathbf{y}) \rangle$$

для некоторого отображения $\phi : X \rightarrow \mathcal{H}$ в гильбертово пространство.

Теорема А.2 (Шур, 1917). *Пусть блочная матрица $M = \begin{pmatrix} A & B \\ B^\top & C \end{pmatrix}$ положительно определена. Тогда $A \succ 0$, $C \succ 0$, матрица $S = C - B^\top A^{-1} B$ (дополнение Шура блока A) положительно определена, и [43, §7.8]*

$$\det M = \det A \cdot \det S.$$

Лемма А.3 (Гронуолл, 1919). *Если непрерывная функция $u : [0, T] \rightarrow [0, \infty)$ удовлетворяет неравенству $u(t) \leq a + b \int_0^t u(\tau) d\tau$ с постоянными $a, b \geq 0$, то [44, гл. 2]*

$$u(t) \leq a e^{bt}, \quad t \in [0, T].$$

В Доказательства

Доказательство теоремы 3.6.

Обозначим $D(x, y)^2 = \int_T \|\varphi_x(t) - \varphi_y(t)\|^p d\mu(t)$.

Условная отрицательная определённость D^2 . При каждом t функция $(x, y) \mapsto \|\varphi_x(t) - \varphi_y(t)\|^p = (\|\varphi_x(t) - \varphi_y(t)\|^2)^{p/2}$ условно отрицательно определена: квадрат евклидовой нормы УОО (теорема 3.5(iii)), а показатель $p/2 \leq 1$ сохраняет УОО (теорема 3.5, часть о степенях). Интегрирование по мере $\mu \geq 0$ сохраняет УОО: при $\sum_i c_i = 0$

$$\sum_{i,j} c_i c_j D(x_i, x_j)^2 = \int_T \left(\sum_{i,j} c_i c_j \|\varphi_{x_i}(t) - \varphi_{x_j}(t)\|^p \right) d\mu(t) \leq 0,$$

так как подынтегральная сумма неположительна при каждом t . Значит D^2

условно отрицательно определена, симметрична и имеет нулевую диагональ.

Метричность D . По теореме 3.5(iii), применённой к D^2 , существуют гильбертово пространство $\mathcal{H}$ и отображение $\Psi : x \mapsto \Psi(x) \in \mathcal{H}$ с $D(x, y)^2 = \|\Psi(x) - \Psi(y)\|_{\mathcal{H}}^2$, то есть $D(x, y) = \|\Psi(x) - \Psi(y)\|_{\mathcal{H}}$. Отсюда симметрия, неотрицательность и неравенство треугольника. Наконец, $D(x, y) = 0$ равносильно $\varphi_x = \varphi_y$ (μ -почти всюду), а в силу инъективности отображения $x \mapsto \varphi_x$ это равносильно $x = y$. Значит D — метрика.

Положительная полуопределённость ядра. Так как D^2 условно отрицательно определена и $\beta/2 \leq 1$, степень $D^\beta = (D^2)^{\beta/2}$ также условно отрицательно определена (теорема 3.5, часть о степенях). По теореме 3.5(ii) ядро $e^{-\lambda D^\beta}$ положительно полуопределено при всех $\lambda > 0$. $\square$

Доказательство утверждения 3.11.

При предположении 3.9 поле $\mathbf{s}(\cdot, t)$ липшицево по первому аргументу и непрерывно по t , поэтому правая часть (3) непрерывна по $(\mathbf{z}, t)$, и для каждого $\mathbf{x}$ траектория $\mathbf{z}_{\mathbf{x}}(\cdot)$ — корректно определённая непрерывная кривая на отрезке $[0, 1]$. Так как непрерывная функция на компакте интегрируема с квадратом по конечной мере, вложение $\varphi_{\mathbf{x}} := \mathbf{z}_{\mathbf{x}}(\cdot)$ лежит в $L^2([0, 1], \mu_w; \mathbb{R}^d)$, а расстояние (4) есть в точности квадрат нормы в этом пространстве,

$$D(\mathbf{x}_i, \mathbf{x}_j)^2 = \|\varphi_{\mathbf{x}_i} - \varphi_{\mathbf{x}_j}\|_{L^2}^2 = \int_0^1 \|\varphi_{\mathbf{x}_i}(t) - \varphi_{\mathbf{x}_j}(t)\|^2 d\mu_w(t).$$

Симметрия и равенство $D(\mathbf{x}, \mathbf{x})^2 = 0$ очевидны. Это случай $p = 2$ теоремы 3.6; повторим её рассуждение. При каждом t функция $(\mathbf{x}, \mathbf{y}) \mapsto \|\varphi_{\mathbf{x}}(t) - \varphi_{\mathbf{y}}(t)\|^2$ условно отрицательно определена как квадрат гильбертовой нормы (теорема 3.5(iii)). Интегрирование по неотрицательной мере μ_w сохраняет это свойство: для любых $\mathbf{x}_1, \dots, \mathbf{x}_n$ и чисел c_i с $\sum_i c_i = 0$

$$\sum_{i,j} c_i c_j D(\mathbf{x}_i, \mathbf{x}_j)^2 = \int_0^1 \left(\sum_{i,j} c_i c_j \|\varphi_{\mathbf{x}_i}(t) - \varphi_{\mathbf{x}_j}(t)\|^2 \right) d\mu_w(t) \leq 0,$$

поскольку подынтегральная сумма неположительна при каждом t . Значит D^2 условно отрицательно определена. Наконец, при $\beta \in (0, 2]$ показатель $\beta/2 \leq 1$, и степень $D^\beta = (D^2)^{\beta/2}$ также условно отрицательно определена (теорема 3.5, часть о степенях). $\square$

Доказательство теоремы 3.2.

Матрица $K = K(X)$ положительно полуопределена (определение 3.1), поэтому $I + K \succ 0$ и μ_D определена и неотрицательна.

(C1) Перестановка π объектов заменяет K на $PKP^\top$ с матрицей перестановки P , и $\det(I + PKP^\top) = \det(P(I + K)P^\top) = \det(I + K)$, так что μ_D не меняется.

(C2) Матрица $M = I + K(X \cup Y) = \begin{pmatrix} A & B \\ B^\top & C \end{pmatrix}$ с $A = I + K(X) \succ 0$, $C = I + K(Y) \succ 0$ положительно определена. По теореме A.2 $\det M = \det A \cdot \det S$ с дополнением Шура $S = C - B^\top A^{-1}B$. Так как $B^\top A^{-1}B \succeq 0$, то $0 \prec S \preceq C$, а определитель монотонен на конусе положительно определённых матриц, поэтому $\det M \leq \det A \cdot \det C$. Логарифмируя, получаем $\mu_D(X \cup Y) \leq \mu_D(X) + \mu_D(Y)$.

(C3) Пусть $\mathbf{b} = (k(\mathbf{x}, \mathbf{x}_i))_{i=1}^N$. С учётом $k(\mathbf{x}, \mathbf{x}) = 1$

$$I + K(X \cup (\mathbf{x})) = \begin{pmatrix} I+K & \mathbf{b} \\ \mathbf{b}^\top & 2 \end{pmatrix},$$

дополнение Шура к блоку $I + K$ равно $s = 2 - \mathbf{b}^\top (I + K)^{-1} \mathbf{b}$, и по теореме A.2

$$\Delta := \mu_D(X \cup (\mathbf{x})) - \mu_D(X) = \log s.$$

Верхняя граница. Так как $(I + K)^{-1} \succ 0$, то $\mathbf{b}^\top (I + K)^{-1} \mathbf{b} \geq 0$, откуда $s \leq 2$ и $\Delta \leq \log 2$.

Нижняя граница. Положим $q := \mathbf{b}^\top (I + K)^{-1} \mathbf{b}$, так что $s = 2 - q$ и $\Delta = \log(2 - q)$; нужно оценить q сверху. Матрица

$$\begin{pmatrix} K & \mathbf{b} \\ \mathbf{b}^\top & 1 \end{pmatrix} = K(X \cup (\mathbf{x})) \succeq 0,$$

поэтому для всех $\mathbf{u} \in \mathbb{R}^N$ и $t \in \mathbb{R}$ выполнено

$$\mathbf{u}^\top K \mathbf{u} + 2t \mathbf{b}^\top \mathbf{u} + t^2 \geq 0.$$

Левая часть — квадратный трёхчлен относительно t со старшим коэффициентом 1; его неотрицательность при всех t равносильна неположительности дискриминанта, $4(\mathbf{b}^\top \mathbf{u})^2 - 4\mathbf{u}^\top K \mathbf{u} \leq 0$, то есть

$$(\mathbf{b}^\top \mathbf{u})^2 \leq \mathbf{u}^\top K \mathbf{u} \quad \text{для всех } \mathbf{u} \in \mathbb{R}^N. \quad (6)$$

Положим $\mathbf{v} = (I + K)^{-1}\mathbf{b}$. Тогда $\mathbf{b}^\top \mathbf{v} = q$ и

$$q = \mathbf{b}^\top (I + K)^{-1}\mathbf{b} = \mathbf{v}^\top (I + K)\mathbf{v} = \|\mathbf{v}\|^2 + \mathbf{v}^\top K\mathbf{v}.$$

Подставляя в (6) вектор $\mathbf{u} = \mathbf{v}$, получаем

$$q^2 = (\mathbf{b}^\top \mathbf{v})^2 \leq \mathbf{v}^\top K\mathbf{v} = q - \|\mathbf{v}\|^2, \quad \text{откуда} \quad \|\mathbf{v}\|^2 \leq q - q^2.$$

С другой стороны, нормировка ядра на расширенной выборке $X \cup (\mathbf{x})$ даёт $|b_i| \leq 1$ (определение 3.1), поэтому $\|\mathbf{b}\|^2 \leq N$, и по неравенству Коши–Буняковского

$$q = \mathbf{b}^\top \mathbf{v} \leq \|\mathbf{b}\| \|\mathbf{v}\| \leq \sqrt{N} \|\mathbf{v}\|, \quad \text{то есть} \quad \|\mathbf{v}\|^2 \geq \frac{q^2}{N}.$$

Объединяя две оценки на $\|\mathbf{v}\|^2$, имеем $q^2/N \leq q - q^2$, откуда $q(N + 1) \leq N$ и

$$q \leq \frac{N}{N + 1}, \quad \Delta = \log(2 - q) \geq \log\left(2 - \frac{N}{N + 1}\right) = \log \frac{N + 2}{N + 1} > 0.$$

□

Доказательство следствия 3.3.

Зафиксируем объект $\mathbf{x}$. Как в доказательстве теоремы 3.2, пункт (С3), прирост сложности при добавлении $\mathbf{x}$ к подвыборке S равен

$$\Delta_S := \mu_D(S \cup (\mathbf{x})) - \mu_D(S) = \log s_S, \quad s_S = 2 - \mathbf{b}_S^\top (I + K(S))^{-1} \mathbf{b}_S,$$

где $\mathbf{b}_S = (k(\mathbf{x}, \mathbf{s}))_{\mathbf{s} \in S}$ и учтено $k(\mathbf{x}, \mathbf{x}) = 1$. Так как $\log$ монотонен, утверждение равносильно неравенству $s_B \leq s_A$ при $A \subseteq B$: достаточно показать, что величина s_S не возрастает при расширении подвыборки.

Матрица $K(B \cup (\mathbf{x}))$ положительно полуопределена, поэтому допускает грам-разложение (теорема A.1): найдутся векторы $\{\phi_{\mathbf{s}}\}_{\mathbf{s} \in B}$ и $\phi_{\mathbf{x}}$ в гильбертовом пространстве, для которых $\langle \phi_{\mathbf{u}}, \phi_{\mathbf{v}} \rangle = k(\mathbf{u}, \mathbf{v})$; в частности $\|\phi_{\mathbf{x}}\|^2 = k(\mathbf{x}, \mathbf{x}) = 1$ и $\langle \phi_{\mathbf{x}}, \phi_{\mathbf{s}} \rangle = (\mathbf{b}_S)_{\mathbf{s}}$.

Для подвыборки $S \subseteq B$ рассмотрим квадратичную функцию на $\mathbb{R}^S$

$$Q_S(\mathbf{w}) = 2 - 2\mathbf{b}_S^\top \mathbf{w} + \mathbf{w}^\top (I + K(S))\mathbf{w}.$$

Она строго выпукла, так как $I + K(S) \succ 0$; приравнивая градиент нулю,

$$\nabla Q_S(\mathbf{w}) = -2 \mathbf{b}_S + 2(I + K(S))\mathbf{w} = \mathbf{0} \implies \mathbf{w}^* = (I + K(S))^{-1} \mathbf{b}_S,$$

находим единственный минимум со значением

$$\min_{\mathbf{w} \in \mathbb{R}^S} Q_S(\mathbf{w}) = Q_S(\mathbf{w}^*) = 2 - \mathbf{b}_S^\top (I + K(S))^{-1} \mathbf{b}_S = s_S.$$

С другой стороны, раскрывая квадрат нормы через грам-разложение и пользуясь $\langle \phi_{\mathbf{x}}, \phi_{\mathbf{s}} \rangle = (\mathbf{b}_S)_{\mathbf{s}}$, $\langle \phi_{\mathbf{s}}, \phi_{\mathbf{s}'} \rangle = K(S)_{\mathbf{s}\mathbf{s}'}$ и $\|\phi_{\mathbf{x}}\|^2 = 1$, получаем

$$\left\| \phi_{\mathbf{x}} - \sum_{\mathbf{s} \in S} w_{\mathbf{s}} \phi_{\mathbf{s}} \right\|^2 = 1 - 2 \mathbf{b}_S^\top \mathbf{w} + \mathbf{w}^\top K(S) \mathbf{w},$$

а прибавив $1 + \|\mathbf{w}\|^2$ и учтя $\mathbf{w}^\top (I + K(S)) \mathbf{w} = \|\mathbf{w}\|^2 + \mathbf{w}^\top K(S) \mathbf{w}$,

$$Q_S(\mathbf{w}) = 1 + \|\mathbf{w}\|^2 + \left\| \phi_{\mathbf{x}} - \sum_{\mathbf{s} \in S} w_{\mathbf{s}} \phi_{\mathbf{s}} \right\|^2 = F(\mathbf{w}), \quad F(\mathbf{w}) := 1 + \|\mathbf{w}\|^2 + \left\| \phi_{\mathbf{x}} - \sum_{\mathbf{s} \in B} w_{\mathbf{s}} \phi_{\mathbf{s}} \right\|^2,$$

где F задана на всём $\mathbb{R}^B$ и от S не зависит, а при $\text{supp } \mathbf{w} \subseteq S$ суммы по B и по S совпадают, так что $F(\mathbf{w}) = Q_S(\mathbf{w})$. Объединяя два равенства, приходим к вариационному представлению

$$s_S = \min_{\text{supp } \mathbf{w} \subseteq S} F(\mathbf{w}).$$

Пусть $A \subseteq B$. Минимум, задающий s_A , берётся по векторам с носителем в A , а минимум для s_B — по всем $\mathbf{w} \in \mathbb{R}^B$, то есть по более широкому множеству при том же F . Поэтому

$$s_B = \min_{\mathbf{w} \in \mathbb{R}^B} F(\mathbf{w}) \leq \min_{\text{supp } \mathbf{w} \subseteq A} F(\mathbf{w}) = s_A,$$

откуда $\Delta_B = \log s_B \leq \log s_A = \Delta_A$. □

Доказательство утверждения 3.12.

Шаг 1: оценки траекторий. Зафиксируем два начальных условия $\mathbf{x}, \mathbf{x}'$ и обозначим $\delta(t) = \mathbf{z}_{\mathbf{x}}(t) - \mathbf{z}_{\mathbf{x}'}(t)$. Интегрируя (3) от 0 до t , запишем уравнение в

интегральной форме

$$\delta(t) = (\mathbf{x} - \mathbf{x}') - \int_0^t \sigma(\tau) \dot{\sigma}(\tau) [\mathbf{s}(\mathbf{z}_{\mathbf{x}}(\tau), \tau) - \mathbf{s}(\mathbf{z}_{\mathbf{x}'}(\tau), \tau)] d\tau.$$

По предположению 3.9 поле $\mathbf{s}$ липшицево по первому аргументу с константой L , а $\sigma \dot{\sigma} \leq C$, поэтому

$$\|\delta(t)\| \leq \|\mathbf{x} - \mathbf{x}'\| + CL \int_0^t \|\delta(\tau)\| d\tau.$$

Применяя неравенство Гронуолла (лемма A.3) с $a = \|\mathbf{x} - \mathbf{x}'\|$ и $b = CL$, получаем

$$\|\delta(t)\| \leq e^{CLt} \|\mathbf{x} - \mathbf{x}'\| \leq e^{CL} \|\mathbf{x} - \mathbf{x}'\|, \quad t \in [0, 1].$$

Так как μ_w — вероятностная мера на $[0, 1]$, отсюда

$$\|\Phi(\mathbf{x}) - \Phi(\mathbf{x}')\|_{\mathcal{H}}^2 = \int_0^1 \|\delta(t)\|^2 d\mu_w(t) \leq e^{2CL} \|\mathbf{x} - \mathbf{x}'\|^2,$$

и после извлечения корня — пункт (i).

Пусть теперь $\widehat{\mathbf{s}}$ — второе скор-поле, а $\widehat{\mathbf{z}}_{\mathbf{x}}$ — решение (3) с тем же начальным условием $\mathbf{x}$, но с полем $\widehat{\mathbf{s}}$. Для разности $\widehat{\delta}(t) = \mathbf{z}_{\mathbf{x}}(t) - \widehat{\mathbf{z}}_{\mathbf{x}}(t)$ начальный член обнуляется; прибавив и вычтя под интегралом $\sigma \dot{\sigma} \mathbf{s}(\widehat{\mathbf{z}}_{\mathbf{x}}, \cdot)$ и пользуясь оценкой $\|\mathbf{s} - \widehat{\mathbf{s}}\| \leq \varepsilon$ вместе с липшицевостью $\mathbf{s}$, имеем

$$\|\widehat{\delta}(t)\| \leq C \int_0^t (L \|\widehat{\delta}(\tau)\| + \varepsilon) d\tau = C\varepsilon t + CL \int_0^t \|\widehat{\delta}(\tau)\| d\tau \leq C\varepsilon + CL \int_0^t \|\widehat{\delta}(\tau)\| d\tau,$$

где в последнем переходе учтено $t \leq 1$. Снова по лемме A.3 (с $a = C\varepsilon$, $b = CL$)

$$\|\widehat{\delta}(t)\| \leq C\varepsilon e^{CLt} \leq C\varepsilon e^{CL}, \quad t \in [0, 1],$$

откуда, как и выше, $\|\Phi(\mathbf{x}) - \widehat{\Phi}(\mathbf{x})\|_{\mathcal{H}} \leq C\varepsilon e^{CL}$ для всех $\mathbf{x}$.

Шаг 2: от ядра к мере. Покажем, что для любых ППО-матриц K, K' с единичной диагональю выполнено

$$|\log \det(I + K') - \log \det(I + K)| \leq \sum_{i \neq j} |K'_{ij} - K_{ij}|. \quad (7)$$

Соединим K и K' отрезком $K_\tau = K + \tau\Delta$, где $\Delta = K' - K$ и $\tau \in [0, 1]$. Конус ППО-матриц выпуклый, поэтому $K_\tau \succeq 0$, а значит $I + K_\tau \succeq I \succ 0$ обратима при всех τ ; функция

$$f(\tau) = \log \det(I + K_\tau)$$

определена и дифференцируема на $[0, 1]$, причём

$$f'(\tau) = \text{tr}((I + K_\tau)^{-1} \Delta) = \sum_{i,j} [(I + K_\tau)^{-1}]_{ji} \Delta_{ij}.$$

Каждый элемент матрицы не превосходит по модулю её спектральной нормы, $|[(I + K_\tau)^{-1}]_{ji}| \leq \|(I + K_\tau)^{-1}\|_2$, а из $I + K_\tau \succeq I$ следует $\|(I + K_\tau)^{-1}\|_2 \leq 1$. Диагональ обнуляется, $\Delta_{ii} = K'_{ii} - K_{ii} = 1 - 1 = 0$, поэтому

$$|f'(\tau)| \leq \sum_{i,j} |[(I + K_\tau)^{-1}]_{ji}| |\Delta_{ij}| \leq \sum_{i \neq j} |\Delta_{ij}| =: B, \quad \tau \in [0, 1].$$

Функция f непрерывна на $[0, 1]$ и дифференцируема на $(0, 1)$, поэтому по теореме Лагранжа о среднем найдётся точка $\xi \in (0, 1)$, для которой $f(1) - f(0) = f'(\xi)(1 - 0) = f'(\xi)$. Следовательно

$$|\log \det(I + K') - \log \det(I + K)| = |f(1) - f(0)| = |f'(\xi)| \leq B,$$

что и есть (7).

Шаг 3: от расстояний к ядру. Функция $g(u) = e^{-\lambda u^2}$ липшицева на $[0, \infty)$: её производная ограничена,

$$\sup_{u \geq 0} |g'(u)| = \sup_{u \geq 0} 2\lambda u e^{-\lambda u^2} = \sqrt{2\lambda/e}$$

(максимум достигается при $u = 1/\sqrt{2\lambda}$). Поэтому для любых пар траекторий с расстояниями $D, \tilde{D}$

$$|e^{-\lambda D^2} - e^{-\lambda \tilde{D}^2}| \leq \sqrt{2\lambda/e} |D - \tilde{D}|,$$

а по обратному неравенству треугольника в $\mathcal{H}$ изменение расстояния $D(\mathbf{x}_i, \mathbf{x}_j) = \|\Phi(\mathbf{x}_i) - \Phi(\mathbf{x}_j)\|_{\mathcal{H}}$ не превосходит суммы сдвигов вложений его аргументов.

Пункт (ii). При замене $\mathbf{x}_k \mapsto \mathbf{x}'_k$ меняются лишь расстояния, в которые

входит k -й объект, — это $2(N - 1)$ внедиагональных записей ядра (k -я строка и k -й столбец без диагонали). Сдвигается вложение только одного аргумента, поэтому по шагам 3 и 1 каждая такая запись меняется не более чем на

$$\sqrt{2\lambda/e} \|\Phi(\mathbf{x}_k) - \Phi(\mathbf{x}'_k)\|_{\mathcal{H}} \leq \sqrt{2\lambda/e} e^{CL} \|\mathbf{x}_k - \mathbf{x}'_k\|.$$

Подставляя это в (7), получаем

$$|\mu_D(X') - \mu_D(X)| \leq 2(N - 1)\sqrt{2\lambda/e} e^{CL} \|\mathbf{x}_k - \mathbf{x}'_k\| \leq 2N\sqrt{2\lambda/e} e^{CL} \|\mathbf{x}_k - \mathbf{x}'_k\|,$$

то есть (ii).

Пункт (iii). При замене поля $\mathbf{s} \mapsto \widehat{\mathbf{s}}$ сдвигаются вложения всех объектов, поэтому меняются все $N(N - 1)$ внедиагональных расстояний; у каждого сдвигаются вложения обоих аргументов, и по шагам 3 и 1 изменение записи не превосходит

$$\sqrt{2\lambda/e} (\|\Phi(\mathbf{x}_i) - \widehat{\Phi}(\mathbf{x}_i)\|_{\mathcal{H}} + \|\Phi(\mathbf{x}_j) - \widehat{\Phi}(\mathbf{x}_j)\|_{\mathcal{H}}) \leq 2\sqrt{2\lambda/e} C\epsilon e^{CL}.$$

Диагональ ядра остаётся единичной, поэтому из (7)

$$|\mu_D(X) - \widehat{\mu}_D(X)| \leq N(N - 1) \cdot 2\sqrt{2\lambda/e} C\epsilon e^{CL} \leq 2N^2\sqrt{2\lambda/e} C e^{CL} \epsilon,$$

то есть (iii). □

Список литературы

1. Towards Bridging Sample Complexity and Model Capacity / S. Mei [и др.] // Proceedings of the AAAI Conference on Artificial Intelligence. — 2022. — Т. 36, № 2. — С. 1972—1980. — DOI: [10.1609/aaai.v36i2.20092](https://doi.org/10.1609/aaai.v36i2.20092).
2. *Konz N., Mazurowski M. A.* The Effect of Intrinsic Dataset Properties on Generalization: Unraveling Learning Differences Between Natural and Medical Images // The Twelfth International Conference on Learning Representations (ICLR 2024). — 2024. — arXiv: [2401.08865](https://arxiv.org/abs/2401.08865) [cs.CV].
3. *Chen S., Dobriban E., Lee J. H.* A Group-Theoretic Framework for Data Augmentation // Journal of Machine Learning Research. — 2020. — Т. 21, № 245. — С. 1—71. — URL: <https://jmlr.org/papers/v21/20-163.html>.
4. SemDeDup: Data-Efficient Learning at Web-Scale through Semantic Deduplication / A. Abbas [и др.]. — 2023. — arXiv: [2303.09540](https://arxiv.org/abs/2303.09540) [cs.LG].
5. *Birodkar V., Mobahi H., Bengio S.* Semantic Redundancies in Image-Classification Datasets: The 10% You Don't Need. — 2019. — arXiv: [1901.11409](https://arxiv.org/abs/1901.11409) [cs.CV].
6. Scaling Laws for Neural Language Models / J. Kaplan [и др.] // arXiv preprint arXiv:2001.08361. — 2020. — arXiv: [2001.08361](https://arxiv.org/abs/2001.08361) [cs.LG].
7. Sub-Scaling Laws: On the Role of Data Density and Training Strategies in LLMs / Z. Chen [и др.] // arXiv preprint arXiv:2507.10613. — 2025. — arXiv: [2507.10613](https://arxiv.org/abs/2507.10613) [cs.LG].
8. Deduplicating Training Data Makes Language Models Better / K. Lee [и др.] // Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers) / под ред. S. Muresan, P. Nakov, A. Villavicencio. — Dublin, Ireland : Association for Computational Linguistics, 05.2022. — С. 8424—8445. — DOI: [10.18653/v1/2022.acl-long.577](https://doi.org/10.18653/v1/2022.acl-long.577).
9. Beyond neural scaling laws: beating power law scaling via data pruning / B. Sorscher [и др.] // Advances in Neural Information Processing Systems. Т. 35 / под ред. S. Koyejo [и др.]. — Curran Associates, Inc., 2022. —

- C. 19523—19536. — arXiv: [2206.14486 \[cs.LG\]](#). — NeurIPS 2022 Outstanding Paper Award.
10. *Geyer C. J.* Practical Markov Chain Monte Carlo // Statistical Science. — 1992. — Т. 7, № 4. — С. 473—483. — DOI: [10.1214/ss/1177011137](#).
 11. Curriculum Learning / Y. Bengio [и др.] // Proceedings of the 26th Annual International Conference on Machine Learning (ICML). — 2009. — С. 41—48. — DOI: [10.1145/1553374.1553380](#).
 12. *Kumar M. P., Packer B., Koller D.* Self-Paced Learning for Latent Variable Models // Advances in Neural Information Processing Systems 23 (NIPS). — 2010. — С. 1189—1197.
 13. Dataset Cartography: Mapping and Diagnosing Datasets with Training Dynamics / S. Swayamdipta [и др.] // Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP). — Association for Computational Linguistics, 2020. — С. 9275—9293. — DOI: [10.18653/v1/2020.emnlp-main.746](#).
 14. *Rahane A. A., Subramanian A.* Measures of Complexity for Large Scale Image Datasets // 2020 International Conference on Artificial Intelligence in Information and Communication (ICAIIIC). — IEEE, 2020. — С. 282—287. — DOI: [10.1109/ICAIIIC48513.2020.9065274](#). — arXiv: [2008.04431 \[cs.CV\]](#).
 15. *Ho T. K., Basu M.* Complexity Measures of Supervised Classification Problems // IEEE Transactions on Pattern Analysis and Machine Intelligence. — 2002. — Март. — Т. 24, № 3. — С. 289—300. — DOI: [10.1109/34.990132](#).
 16. How Complex Is Your Classification Problem? A Survey on Measuring Classification Complexity / A. C. Lorena [и др.] // ACM Computing Surveys. — 2019. — Т. 52, № 5. — DOI: [10.1145/3347711](#).
 17. *Smith M. R., Martinez T., Giraud-Carrier C.* An Instance Level Analysis of Data Complexity // Machine Learning. — 2014. — Т. 95, № 2. — С. 225—256. — DOI: [10.1007/s10994-013-5422-z](#).
 18. *Ванник В. Н., Червоненкис А. Я.* Теория распознавания образов: статистические проблемы обучения. — М. : Наука, 1974.

19. *Koltchinskii V., Panchenko D.* Rademacher Processes and Bounding the Risk of Function Learning // High Dimensional Probability II / под ред. E. Giné, D. M. Mason, J. A. Wellner. — Boston, MA : Birkhäuser, 2000. — С. 443—457.
20. LIDL: Local Intrinsic Dimension Estimation Using Approximate Likelihood / P. Tempczyk [и др.] // Proceedings of the 39th International Conference on Machine Learning (ICML 2022). Т. 162. — 2022. — С. 21205—21231. — (Proceedings of Machine Learning Research). — arXiv: [2206 . 14882](https://arxiv.org/abs/2206.14882) [[cs.LG](#)].
21. A Geometric View of Data Complexity: Efficient Local Intrinsic Dimension Estimation with Diffusion Models / H. Kamkari [и др.] // Advances in Neural Information Processing Systems 37 (NeurIPS 2024). — 2024. — arXiv: [2406.03537](https://arxiv.org/abs/2406.03537) [[cs.LG](#)].
22. *Roy O., Vetterli M.* The Effective Rank: A Measure of Effective Dimensionality // Proceedings of the 15th European Signal Processing Conference (EUSIPCO). — Poznan, Poland : EURASIP, 2007. — С. 606—610.
23. *Friedman D., Dieng A. B.* The Vendi Score: A Diversity Evaluation Metric for Machine Learning // Transactions on Machine Learning Research. — 2023. — ISSN 2835-8856. — arXiv: [2210 . 02410](https://arxiv.org/abs/2210.02410) [[cs.LG](#)]. — URL: <https://openreview.net/forum?id=g970HbQyk1> ; Published 07/2023, OpenReview id g970HbQyk1.
24. *Narayanan H.* Sample Complexity in Manifold Learning // Manifold Learning Theory and Applications / под ред. Y. Ma, Y. Fu. — Boca Raton, FL : CRC Press, 2011. — С. 73—86.
25. *Ma Y., Fu Y.* Manifold Learning Theory and Applications. — CRC Press, 12.2011.
26. *Fefferman C., Mitter S., Narayanan H.* Testing the Manifold Hypothesis // Journal of the American Mathematical Society. — 2016. — Т. 29, № 4. — С. 983—1049. — DOI: [10.1090/jams/852](https://doi.org/10.1090/jams/852).
27. The Intrinsic Dimension of Images and Its Impact on Learning / P. Pope [и др.] // 9th International Conference on Learning Representations (ICLR). — 2021. — arXiv: [2104.08894](https://arxiv.org/abs/2104.08894) [[cs.LG](#)].

28. *Grabovoy A. V.* О сложности моделей и данных в параметрических моделях глубокого обучения : Doctoral dissertation / Grabovoy Andrey V. — Moscow : Moscow Institute of Physics, Technology, 2025.
29. *Berg C., Christensen J. P. R., Ressel P.* Harmonic Analysis on Semigroups: Theory of Positive Definite and Related Functions. Т. 100. — New York : Springer, 1984. — (Graduate Texts in Mathematics).
30. *Krause A., Singh A., Guestrin C.* Near-Optimal Sensor Placements in Gaussian Processes: Theory, Efficient Algorithms and Empirical Studies // Journal of Machine Learning Research. — 2008. — Т. 9. — С. 235—284. — URL: <https://jmlr.org/papers/v9/krause08a.html>.
31. Gaussian Process Optimization in the Bandit Setting: No Regret and Experimental Design / N. Srinivas [и др.] // Proceedings of the 27th International Conference on Machine Learning (ICML). — Omnipress, 2010. — С. 1015—1022. — arXiv: [0912.3995](https://arxiv.org/abs/0912.3995) [cs.LG].
32. *Cover T. M., Thomas J. A.* Elements of Information Theory. — 2nd. — Hoboken, NJ : Wiley-Interscience, 2006.
33. *Alpay D., Mayats-Alpay L.* Similarity Metrics, Metrics, and Conditionally Negative Definite Functions // arXiv preprint arXiv:2307.10446. — 2023. — math.FA.
34. Score-Based Generative Modeling through Stochastic Differential Equations / Y. Song [и др.] // International Conference on Learning Representations (ICLR). — 2021.
35. *Bishop C. M., Bishop H.* Deep Learning: Foundations and Concepts. — Cham : Springer, 2024.
36. *Azeglio S., Di Bernardo A.* What's Inside Your Diffusion Model? A Score-Based Riemannian Metric to Explore the Data Manifold // arXiv preprint arXiv:2505.11128. — 2025. — arXiv: [2505.11128](https://arxiv.org/abs/2505.11128) [cs.LG].
37. Perception Prioritized Training of Diffusion Models / J. Choi [и др.] // IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2022. — С. 11472—11481. — DOI: [10.1109/CVPR52688.2022.01118](https://doi.org/10.1109/CVPR52688.2022.01118).

38. *Song J., Meng C., Ermon S.* Denoising Diffusion Implicit Models // 9th International Conference on Learning Representations (ICLR). — 2021. — arXiv: [2010.02502](https://arxiv.org/abs/2010.02502) [cs.LG].
39. Diffusion Autoencoders: Toward a Meaningful and Decodable Representation / K. Preechakul [и др.] // IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). — 2022. — С. 10619—10629. — DOI: [10.1109/CVPR52688.2022.01036](https://doi.org/10.1109/CVPR52688.2022.01036).
40. *Kwon M., Jeong J., Uh Y.* Diffusion Models Already Have a Semantic Latent Space // 11th International Conference on Learning Representations (ICLR). — 2023. — arXiv: [2210.10960](https://arxiv.org/abs/2210.10960) [cs.CV].
41. *Pasarkar A. P., Dieng A. B.* Cousins of the Vendi Score: A Family of Similarity-Based Diversity Metrics for Science and Machine Learning // Proceedings of the 27th International Conference on Artificial Intelligence and Statistics (AISTATS). T. 238. — PMLR, 2024. — С. 3808—3816. — (Proceedings of Machine Learning Research). — arXiv: [2310.12952](https://arxiv.org/abs/2310.12952) [cs.LG]. — URL: <https://proceedings.mlr.press/v238/pasarkar24a.html>.
42. *Aronszajn N.* Theory of reproducing kernels // Transactions of the American Mathematical Society. — 1950. — Т. 68, № 3. — С. 337—404.
43. *Horn R. A., Johnson C. R.* Matrix Analysis. — 2nd. — Cambridge University Press, 2013.
44. *Teschl G.* Ordinary Differential Equations and Dynamical Systems. T. 140. — Providence, RI : American Mathematical Society, 2012. — (Graduate Studies in Mathematics).