

Геометрический подход к оценке сложности данных на основе генеративных диффузионных моделей

Черноусов Данила Владиславович

Московский физико-технический институт

03.03.01 Прикладные математика и физика

Научный руководитель к.ф.-м.н. А. В. Грабовой

МФТИ, г. Долгопрудный
2026 г.

Зачем измерять сложность данных:

- ▶ **Интерпретируемость** — предсказание качества модели по характеристикам обучающей выборки, а не только по её размеру
- ▶ **Адаптивное обучение** — обучающие батчи с учётом сложности батча
- ▶ **Оценка разнообразия** — сравнение выборок одного размера, но разного содержания

Постановка проблемы

Исследуемая проблема

Построение интерпретируемой меры сложности выборки данных, согласованной с геометрией порождающего распределения.

Задачи

1. Предложить метод оценки сложности выборки, учитывающий семантическую структуру данных.
2. Исследовать достаточные условия корректности меры сложности выборки.

Метод

Предлагается извлекать геометрию данных из предобученной диффузионной модели, сопоставляя каждому объекту его траекторию порождающего процесса — описание объекта сразу на всех масштабах. Сложность выборки определяется как эффективный объём, который она занимает в пространстве траекторий.

Определение меры сложности

Выборка $X = (x_1, \dots, x_N)$, $x_i \in \mathbb{R}^d$,

Определение

Мерой сложности назовём отображение $\mu_D(X) \in \mathbb{R}_+$, удовлетворяющее трём свойствам:

1. **Инвариантность к перестановкам:** $\mu_D(\pi X) = \mu_D(X)$, $\pi \in S_N$;
2. **Субаддитивность:** $\mu_D(X \cup Y) \leq \mu_D(X) + \mu_D(Y)$;
3. **Монотонность:** $\mu_D(X) \leq \mu_D(X \cup \{x\})$.

Предлагаемый метод


Зададим симметричное ядро $k(x, y)$ — меру похожести объектов, и построим по его матрице $K = (k(x_i, x_j))$ меру сложности

$$\mu_D(X) = \log \det(I + K).$$

Теорема (Черноусов, 2026)

Пусть ядро k положительно полуопределено ($K \succeq 0$) и $k(x, x) = 1$ для любого x . Тогда $\mu_D(X) = \log \det(I + K)$ — мера сложности: выполнены свойства (1)–(3).

Свойства и интерпретация



верх — разнообразная выборка, низ — дубликаты

Нужен ли? (график)

Теорема (Черноусов, 2026)

Пусть ядро k положительно полуопределено, $k(x, x) = 1$ для любого x . Тогда для любой выборки X объёма N и объекта x

$$\log \frac{N+2}{N+1} \leq \mu_D(X \cup \{x\}) - \mu_D(X) \leq \log 2.$$

Следствие

$$\log(N+1) \leq \mu_D(X) \leq N \log 2, \quad N = |X|.$$

$\mu_D = \sum_k \log(1 + \nu_k)$ — эффективное число независимых направлений.

Метрика в пространстве объектов

Теорема (Черноусов, 2026)

Пусть (T, w) — пространство с мерой, $p \in (0, 2]$, $\beta \in (0, 2]$, $\lambda > 0$, и отображение $x \mapsto \varphi_x \in L^p(T, w; \mathbb{R}^d)$ инъективно. Тогда

$$D(x, y) = \left(\int_T \|\varphi_x(t) - \varphi_y(t)\|^p w(t) dt \right)^{1/2}$$

— метрика, а ядро $k(x, y) = e^{-\lambda D(x, y)^\beta}$ положительно полуопределено.

$\beta = 2$: гауссово $e^{-\lambda D^2}$ (MSE); $\beta = 1$: лапласово $e^{-\lambda D}$.

Диффузионный процесс и поток вероятности

Обозначим за p плотность распределения данных, а тогда зашумление и скор-функция:

$$p_t = p * \mathcal{N}(0, \sigma^2(t)I), \quad s(x, t) = \nabla_x \log p_t(x).$$

Стохастическому процессу зашумления соответствует детерминированное **ОДУ вероятностного потока** с теми же маргинальными плотностями p_t при каждом t [Song и др., 2021]:

$$\frac{dz}{dt} = -\dot{\sigma} \sigma s(z, t), \quad z(0) = x.$$

Объект идёт по **единственной** траектории от данных к шуму.


Траектория проходит все уровни шума и на разных масштабах кодирует разную близость объектов:

► малый шум ($t \rightarrow 0$): **синтаксис**
(форма, внешний вид);

► большой шум ($t \rightarrow 1$): **семантика**
(класс, смысл).

Истинный скор $\nabla_x \log p_t$ неизвестен; его **оценивает** обученная диффузионная модель $s_\theta \approx \nabla_x \log p_t$.

Предлагаемый метод: траекторное вложение



Вложение $\Phi(x) = z_x(\cdot) \in \mathcal{H} = L^2([0, 1]; \mathbb{R}^d)$: объект описан всей траекторией, на всех уровнях шума. Расстояние с весом $w(t) = \text{Beta}(t; a, b)$:

$$D^2(x_i, x_j) = \int_0^1 \|z_{x_i}(t) - z_{x_j}(t)\|^2 \underbrace{w(t)}_{\text{вес масштаба}} dt.$$

$$\mu_D(X) = \log \det \left(I + \left(e^{-\lambda \int_0^1 \|z_{x_i}(t) - z_{x_j}(t)\|^2 w(t) dt} \right)_{i,j=1}^N \right)$$


Вычислительная сложность

Для выборки объёма N мера $\mu_D(X)$ считается в три этапа:

1. **Расшумление моделью:** N траекторий по S шагов ОДУ (проход модели стоимости C): $O(N S C)$.
2. **Попарные расстояния** D_{ij}^2 : интеграл по L узлам времени, $O(N^2 L d)$.
3. **Мера** $\log \det(I + K)$: разложение $N \times N$, $O(N^3)$.

Итого: $O(N S C + N^2 L d + N^3)$
--


Эксперимент 1: скорость роста



Синтетическая смесь гауссиан,
 $d = 2$, аналитическая скор-функция.

- ▶ N кластеров по 1 точке:
 $\mu_D \approx N \log 2$;
- ▶ один кластер, $\sigma = 0.1$:
 $\mu_D \approx \log(1 + N)$;
- ▶ один кластер, $\sigma = 1$:
промежуточный рост.

Эксперимент 2: MNIST



Предобученная DDPM, ОДУ
вероятностного потока.

- ▶ один класс vs несколько классов;
- ▶ μ_D мультикласса растёт быстрее;
- ▶ разнообразные данные $\rightarrow$ большая сложность.

Выносятся на защиту

1. Доказана теорема о достаточном условии корректности меры сложности выборки.
2. Доказана теорема о свойствах предложенной меры.
3. Предложен метод оценки сложности на основе траекторного вложения диффузионной модели.
4. Экспериментально подтверждена семантическая согласованность предложенной меры.