

Геометрический подход к оценке сложности данных на основе генеративных диффузионных моделей

Черноусов Данила Владиславович

Московский физико-технический институт

03.03.01 Прикладные математика и физика

Научный руководитель к.ф.-м.н. А. В. Грабовой

МФТИ, г. Долгопрудный
2026 г.

Зачем измерять сложность данных:

- ▶ **Интерпретируемость** — предсказание качества модели по характеристикам обучающей выборки, а не только по её размеру
- ▶ **Адаптивное обучение** — обучающие батчи с учётом сложности данных
- ▶ **Оценка разнообразия** — сравнение выборок одного размера, но разного содержания

Постановка задачи

Исследуемая проблема

Построение интерпретируемой меры сложности выборки данных, согласованной с геометрией порождающего распределения.

Задачи

1. Исследовать достаточные условия корректности меры сложности выборки.
2. Предложить метод оценки сложности выборки, учитывающий семантическую структуру данных.

Метод

Сложность выборки строится по симметричному ядру на парах объектов. Мера определяется через матрицу этого ядра, корректность вытекает из достаточных условий. Ядро строится по предобученной диффузионной модели. Объекту сопоставляется его траектория порождающего процесса, описывающая объект сразу на всех масштабах.

Определение меры сложности

Выборка $X = (x_1, \dots, x_N)$, $x_i \in \mathbb{R}^d$,

Определение

Мерой сложности назовём отображение $\mu_D(X) \in \mathbb{R}_+$, удовлетворяющее трём свойствам:

1. **Инвариантность к перестановкам:** $\mu_D(\pi X) = \mu_D(X)$,
 $\pi \in S_N$;
2. **Субаддитивность:** $\mu_D(X \cup Y) \leq \mu_D(X) + \mu_D(Y)$;
3. **Монотонность:** $\mu_D(X) \leq \mu_D(X \cup \{x\})$.

Достаточное условие корректности

Зададим симметричное ядро $k(x, y)$ на парах объектов и построим по его матрице $K = (k(x_i, x_j))$ меру сложности

$$\mu_D(X) = \log \det(I + K).$$

Теорема (Черноусов, 2026)

Пусть ядро k положительно полуопределено ($K \succeq 0$) и $k(x, x) = 1$ для любого x . Тогда $\mu_D(X) = \log \det(I + K)$ — мера сложности: выполнены свойства (1)–(3).

Границы на возрастание сложности

Теорема (Черноусов, 2026)

Пусть ядро k положительно полуопределено, $k(x, x) = 1$ для любого x . Тогда для любой выборки X объёма N и объекта x

$$\log \frac{N+2}{N+1} \leq \mu_D(X \cup \{x\}) - \mu_D(X) \leq \log 2.$$

Следствие

$$\log(N+1) \leq \mu_D(X) \leq N \log 2, \quad N = |X|.$$

Метрика в пространстве объектов

Теорема (Черноусов, 2026)

Пусть (T, w) — пространство с мерой, $p \in (0, 2]$, $\beta \in (0, 2]$, $\lambda > 0$, и отображение $x \mapsto \varphi_x \in L^p(T, w; \mathbb{R}^d)$ инъективно. Тогда

$$D(x, y) = \left(\int_T \|\varphi_x(t) - \varphi_y(t)\|^p w(t) dt \right)^{1/2}$$

— метрика, а ядро $k(x, y) = e^{-\lambda D(x, y)^\beta}$ положительно полуопределено.

$\beta = 2$: гауссово $e^{-\lambda D^2}$; $\beta = 1$: лапласово $e^{-\lambda D}$.

Диффузионный процесс и поток вероятности

Обозначим за p плотность распределения данных, а тогда зашумление и скор-функция:

$$p_t = p * \mathcal{N}(0, \sigma^2(t)I), \quad s(x, t) = \nabla_x \log p_t(x).$$

Стохастическому процессу зашумления соответствует детерминированное **ОДУ вероятностного потока** с теми же маргинальными плотностями p_t при каждом t :

$$\frac{dz}{dt} = -\dot{\sigma} \sigma(z, t), \quad z(0) = x.$$


Объект идёт по единственной траектории от данных к шуму.

Траектория проходит все уровни шума и на разных масштабах кодирует разную близость объектов:

- ▶ малый шум ($t \rightarrow 0$): синтаксис (форма, внешний вид);
- ▶ большой шум ($t \rightarrow 1$): семантика (класс, смысл).

Истинный скор $\nabla_x \log p_t$ неизвестен, его оценивает обученная диффузионная модель $s_\theta \approx \nabla_x \log p_t$.

Предлагаемый метод: траекторное вложение




Вложение $\Phi(x) = z_x(\cdot) \in \mathcal{H} = L^2([0, 1], \mu_w; \mathbb{R}^d)$: объект описан всей траекторией, на всех уровнях шума. Расстояние с весом $w(t) = \text{Beta}(t; a, b)$:

$$D^2(x_i, x_j) = \int_0^1 \|z_{x_i}(t) - z_{x_j}(t)\|^2 \underbrace{w(t)}_{\text{вес масштаба}} dt.$$

$$\mu_D(X) = \log \det \left(I + \left(e^{-\lambda \int_0^1 \|z_{x_i}(t) - z_{x_j}(t)\|^2 w(t) dt} \right)_{i,j=1}^N \right)$$


Эксперимент 1: скорость роста



Синтетическая смесь гауссиан, $d = 2$, аналитическая скор-функция.

- ▶ N кластеров по 1 точке:
 $\mu_D \approx N \log 2$;
- ▶ один кластер, $\sigma = 0.1$:
 $\mu_D \approx \log(1 + N)$;
- ▶ один кластер, $\sigma = 1$:
промежуточный рост.

Эксперимент 2: MNIST



Предобученная DDPM, ОДУ вероятностного потока.

- ▶ один класс vs несколько классов;
- ▶ μ_D мультикласса растёт быстрее;
- ▶ разнообразные данные → большая сложность.

Выносятся на защиту

1. Доказана теорема о достаточном условии корректности меры сложности выборки.
2. Доказана теорема о свойствах предложенной меры.
3. Предложен метод оценки сложности на основе траекторного вложения диффузионной модели.
4. Экспериментально подтверждена семантическая согласованность предложенной меры.

Работы автора по теме ВКР

- ▶ Основные результаты доложены на 68-й Всероссийской научной конференции МФТИ.
- ▶ По теме работы подготовлена статья, поданная на конференцию ISOMP 2026.